



東南大學

毕业设计(论文)

外文资料翻译

翻译资料名称(外文)GeoExplorer: Active Geo-localization with Curiosity-Driven Exploration

翻译资料名称(中文)GeoExplorer: 基于好奇心驱动探索的主动地理定位

院 (系): 自动化学院

专 业: 机器人工程

姓 名: 张洋

学 号: 08122215

指导教师: 朱鹏飞, 朱文成

完成日期: 2026 年 3 月 10 日

GeoExplorer: 基于好奇心驱动探索的主动地理定位

Li Mi¹, Manon B´echaz¹, Zeming Chen¹, Antoine Bosselut¹, Devis Tuia¹

(¹ 瑞士洛桑联邦理工学院)

摘要: 主动地理定位 (Active Geo-localization, AGL) 的任务是在预定义的搜索区域内定位目标, 目标以各种模态 (例如航拍图像、地面图像或文本) 表示。当前的方法将 AGL 视为具有基于距离奖励的目标到达强化学习

(reinforcement learning, RL) 问题, 通过隐式学习来最小化与目标的相对距离来定位目标。然而, 当距离估计变得困难或遇到未见过的目标和环境时, 由于在训练期间学习到的探索策略不够可靠, 代理的鲁棒性和泛化能力会降低。在本文中, 我们提出了 GeoExplorer, 一种通过内在奖励将好奇心驱动的探索结合起来, 从而实现稳健且多样化探索的好 AGL 智能体。与依赖目标距离的外在奖励不同, 好奇心驱动奖励不依赖目标信息, 因此在目标位置未知时仍能提供稳定的探索引导, 能够基于有效的环境建模进行稳健、多样且与上下文相关的探索。通过在四个 AGL 基准上的大量实验, 这些能力已得到证明, 展示了 GeoExplorer 在各种设置中的有效性和泛化能力, 特别是在定位不熟悉的对象和环境中的。

1. 简介

在搜索和救援行动中, 引导无人驾驶飞行器 (无人机) 至关重要, 这需要无人机对受灾区域进行筛查, 并定位失踪人员或受损建筑[23,26]。无人机无需对整个区域进行详尽搜索, 而是可以利用现有信息进行主动引导: 可以使用感兴趣点的坐标、历史航拍图像, 甚至地面照片或文字描述[29,33]。

该问题在计算机视觉领域被称为目标导向强化学习 (RL) 环境下的主动地理定位 (AGL) [29,33] (图 1 (a))。AGL 旨在通过引导智能体向目标移动, 在鸟瞰图中预定义的搜索区域内定位目标。在给定时间, 智能体观察到一个状态, 即代表有限区域的图像块。智能体观察环境, 并选择一个动作, 即一个能改变智能体位置和所观察状态的决策。目标内容可以用多种模态来描述 (例如, 航拍图块、地面图像和文本描述, 图 1 (b)), 但在推理过程中其位置是未知的。如果智能体在有限的搜索预算 (B) 内到达目标位置, 则任务视为成功。在 AGL 的实际应用中, 鲁棒性和泛化能力至关重要, 因为很少有场景是完全相同的[33]。




图 1. GeoExplorer 结合了目标导向型和好奇心驱动型奖励来解决 AGL 问题。(a) 任务设置. 给定一个起始区域 (○) 和一个预定义的搜索区域, AGL 的目标是在该区域内定位一个目标 (△), 通过引导智能体向其靠近来实现。在给定的时间点, 智能体观察到一个状态并选择一个动作。目标的位置在推理过程中是未知的。(b) 目标模式. 目标可以通过多种模式呈现, 包括航拍图像 (I)、地面图像 (G) 和文本 (T), 与区域内的一个区域相关联。(c) GeoExplorer. GeoExplorer 的学习过程由两种奖励引导: 1) 与先前方法类似的目标导向型基于距离的奖励, 引导智能体向目标靠近; 2) 一种与目标无关的好奇心驱动型奖励, 鼓励智能体基于状态预测与观察的相似度所衡量的好奇心来探索环境。(Figure 1. **GeoExplorer combines goal-oriented and curiositydriven rewards to address AGL.** (a) *Task setting.* Given a starting patch (○) and a predefined search area (*environment*), AGL aims at localizing a goal (△), by guiding an agent towards it. At a given time, the agent observes a *state* and selects an *action*. The goal location is *unknown* for inference. (b) *Goal modalities.* The goal can be presented in various modalities including aerial images (I), ground-level images (G) and text (T), associated with a patch in the area. (c) *GeoExplorer.* The learning process of GeoExplorer is guided by two rewards: **1)** a goal-oriented **distance-based** reward, as in previous methods, which directs the agent toward the goal, and **2)** a goal-agnostic, curiosity-driven reward that encourages the agent to explore the environment based on *curiosity* measured by **similarity** of state prediction and observation)

现有的主动地理定位 (AGL) 方法依赖于外部奖励 (即目标导向), 并且在训练过程中策略是通过最小化智能体与目标之间的相对距离来隐式塑造的。然而, 在推理阶段 (因为目标的位置未知), 这个距离是未知的, 这使得所学策略的可靠性降低。此外, 这些距离估计通常是针对特定的训练环境进行定制的, 这使得模型难以适应未见过的环境。无论是面对新的目标还是新的环境, 由好奇心驱动的内在奖励 (即与目标无关) 都提供了一个颇具吸引力的解决方案。通过奖励智能体遇到不太熟悉[6,28]或不可预测[28,41]的状态转换, 这种内在奖励鼓励智能

体探索环境[19,28]。因此，将好奇心驱动的奖励与目标导向的奖励相结合，会在遵循直接的目标导向指引和进行探索性行为之间引入一个重要的权衡。这种平衡确保智能体不仅能高效地达成目标，还能不断细化对环境理解，从而形成有效且适应性强的策略，增强主动地理定位（AGL）的稳健性和泛化能力。

然而，构建内在奖励需要一种预测状态转换的方法，因为它是基于状态预测与实际观察之间的差异。先前的 AGL 方法[29,33]仅专注于预测通向目标的动作序




图 2 (a)), 因此无法满足这一要求。由于没有明确的状态预测, 这些方法也无法准确预测动作如何改变状态, 从而导致适应性降低以及在未知环境中出现累积误差。相反, 联合动作 - 状态建模




图 2 (b)) 鼓励更稳健和适应性强的环境建模与表示优化[3,43], 这对于面对陌生环境或目标至关重要。




图 2. (a) 仅动作预测与 (b) 动作-状态联合建模的方法比较 (Figure 2. Comparison between (a) action-only prediction and (b) joint action-state modeling)

在这项工作中, 我们引入了 GeoExplorer, 这是一种 AGL 智能体, 1) 联合预测动作-状态动态, 2) 利用好奇心驱动的奖励探索搜索区域。GeoExplorer 的学习过程分为两个阶段: 动作-状态动态建模 (Action-State Dynamics Modeling, DM) 和好奇心驱动探索 (Curiosity-Driven Exploration, CE)。DM 同时使用因果

Transformer 模型动作-状态动态，使 GeoExplorer 不仅能够学习哪些动作能达成目标，还能了解这些动作如何影响状态转换，从而提供更丰富、更全面的环境表示。然后，在 CE 阶段，引入一种内在奖励，通过利用 DM 提供的状态预测与现实世界状态观测之间的差异来引导探索过程。在包括一种新颖的未见过的目标泛化设置在内的四个数据集上的实验结果表明，GeoExplorer 为 AGL 提供了密集、目标无关且内容感知的奖励。结合目标导向的引导，GeoExplorer 强调平衡目标达成（外在奖励）和环境探索（内在奖励）能够提升 AGL 代理的定位性能和泛化能力。GeoExplorer 所具备的这种主动且自适应的探索能力，标志着 AGL 向现实世界中的搜索和救援行动部署迈出了重要一步。

2. 相关工作

2.1 主动地理定位

尽管与传统的视觉地理定位相关（即通常侧重于通过坐标预测[2,42]或检索[4,5[24],[44],[47],[49]54]来确定目标的位置），但主动地理定位通过主动引导智能体到达目标而有所不同。当前的主动地理定位方法在从各种无人机定位轨迹中学习动作转换方面取得了显著进展[29,33]。Pirinen 等人[12]将主动地理定位表述为一个以稀疏外部奖励为引导的目标达成强化学习问题。Sarkar 等人[33]通过引入多种目标模式扩展了主动地理定位任务，并提出了目标感知动作建模预训练以及基于距离的外部奖励的 Actor-Critic（演员-评论家）网络强化学习流程。尽管取得了进展，但这些方法都是依靠外部奖励来定位目标，当目标位置未知时，这可能会提供误导性的指导。此外，这种方法无法有效地和全面地建模环境，导致搜索策略效率低下，且难以推广到未见过的区域。GeoExplore 旨在通过同时建模动作-状态动态并启用好奇心驱动的探索来解决这些挑战。

2.2 用于动作状态建模的 Transformer

强化学习领域的最新进展表明，基于因果 Transformer 的序列建模在预测动作方面具有令人兴奋的潜力[8,17]。它们侧重于根据任务规范（例如目标或回报）对动作序列进行预测建模，而非直接学习 Q 函数或策略梯度[11,35,40]。此外，近期的研究工作主要集中在学习世界模型以描述环境上。它们进一步采用 Transformer 架构来建模智能体动作对环境的影响，通过预测未来状态表示[3,43,53]或观测值[48,50]。这些模型通常以先前的状态历史和可能的动作作为输入，并预测下一个状态。然而，这些世界模型主要是为具有连续状态转换的领域（如自动驾驶和机器人技术）而设计的。相比之下，AGL 场景可能涉及通过采取动作而产生的不重叠且突然的状态变化。GeoExplorer 证明，即使在这种情况下

下，状态建模也能增强动作预测，进一步突显了全面环境建模的关键作用。

2.3 好奇心驱动的强化学习

好奇心驱动的探索在强化学习中起着关键作用，它使智能体能够在奖励遥不可及、稀少或根本不存在的环境中进行导航和学习。即使在这些情况下，当内在目标明确时，研究人员主张将内在动机作为鼓励探索的额外奖励加以利用[34]。人们探索了生成内在奖励的不同方法，包括鼓励探索先前未曾遇到的状态[6,28]，在对未来状态和行动结果的预测存在差异时激发好奇心[28,41]，在不确定性高的领域促进探索[19]，以及鼓励智能体使其行为与他人的期望保持一致[22]。在此基础上，我们将好奇心驱动的探索引入 AGL，其中适应性和主动性探索对于泛化至关重要。通过奖励预测状态与实际状态之间的差异，GeoExplorer 展示了将好奇心驱动的强化学习有效集成到序列建模框架中的能力，且无需额外组件。

3. GeoExplorer

3.1 概述

3.1.1 问题描述

依照先前的研究[29,33]，AGL 任务可被表述为一个以到达目标状态为终止条件的目标导向强化学习问题。一架无人机智能体位于起始区域(I_0)，其目标是在一个预先定义的不重叠的 $X \times Y$ 搜索网格内导航，以在搜索预算 (B) 内到达目标位置。在每个时间步 t ，智能体仅能观察到其当前所在的区域 I_t ，并通过采取动作 $a_t \in A$ (向上、向下、向左、向右，以鸟瞰视角考虑) 在区域之间移动。时间步 t 的状态可表示为 s_t ，即当前区域的表示。AGL 的总体目标是确定一条轨迹 $x = \{s_0, a_0, \dots, s_t, a_t, \dots, s_{goal}\}$ ，引导智能体到达目标。在训练期间，目标仅以鸟瞰图 (I_{goal}) 的形式呈现，且位置已知。在推理阶段，目标可以以三种形式之一提供：鸟瞰图、地面图像 (G_{goal}) 或文本 (T_{goal})，但目标的位置未知。

3.1.2 方法概述




图 3. GeoExplorer 学习流程。学习过程可以依次分为三个阶段：特征表示、动作-状态动态建模（DM）和好奇心驱动探索（CE）。（a）特征表示：环境（ s_t ）和目标（ s_{goal} ）根据其模态（例如，航拍图像（ I_{goal} ）、地面图像（ G_{goal} ）或文本（ T_{goal} ））使用不同但对齐的编码器进行编码。（b）动作-状态动态建模：训练一个因果 Transformer 来联合捕捉动作-状态动态，由生成的动作-状态轨迹对环境建模提供监督。（c）好奇心驱动探索：基于（b）中的状态预测，将好奇心驱动的内生奖励（ r_t^{CE} ）与基于距离的外在奖励（ r_t^{in} ）相结合，通过测量预测与观察之间的差异来鼓励智能体探索环境。（Figure 3. GeoExplorer learning pipeline. The learning process can be divided into three stages sequentially: Feature Representation, Action-State Dynamics Modeling (DM), and Curiosity-Driven Exploration (CE). (a) *Feature Representation*. The environment (s_t) and goal (s_{goal}) are encoded with different but aligned encoders, according to their modalities (e.g., aerial images (I_{goal}), ground-level images (G_{goal}), or text (T_{goal})). (b) *Action-State Dynamics Modeling*. A causal Transformer is trained to jointly capture action-state dynamics, guided by supervision from generated action-state trajectories for environment modeling. (c) *Curiosity-Driven Exploration*. Based on state prediction from (b), a curiosity-driven intrinsic reward (r_t^{in}) is combined with the distance-based extrinsic reward (r_t^{ex}) to encourage the agent to explore the environment by measuring the differences between prediction and observations.)

GeoExplorer 的训练过程可分为三个阶段（图 3）：1）特征表示；2）动作-状态动态建模（DM）；3）好奇心驱动探索（CE）。DM 是一个有监督的预训练阶段，在此阶段通过因果 Transformer 对动作-状态动态进行建模。CE 是一个强化学习阶段，在此阶段，用作动作预测头的 Actor-Critic（演员-评论家）网络根据 DM 阶段的输出进行训练以预测动作，同时结合基于距离的奖励和好奇心驱动的奖励。

3.2 特征表示

在 AGL 中，目标以不同的模态呈现。为了实现无论目标本质如何都能进行定位，为每种模态（即航拍图像、地面图像和文本）使用了预对齐的特征编码器，如先前的工作[33]所述，并如图 3（a）所示。这些特定于模态的编码器通过对比

学习[9,32]在联合嵌入空间中进行预训练，以对齐文本-图像对或图像-图像对。更具体地说，地面图像编码器（一个视觉编码器， $CLIP_{img}$ ）和文本编码器（ $CLIP_{text}$ ）来自预训练的 CLIP 模型[32]，而航拍图像编码器（ $Sat2Cap_{img}$ ）则是一个使用地面图像和航拍图像对[9]的 CLIP 图像编码器对齐的 ViT 编码器。该过程可表示为：

$$\begin{aligned} s_{goal} &= \text{Sat2Cap}_{img}(I_{goal}), \\ s_{goal} &= \text{CLIP}_{img}(G_{goal}), \\ s_{goal} &= \text{CLIP}_{text}(T_{goal}). \end{aligned} \quad (1)$$

此外，我们还使用相同的航拍图像编码器对环境进行编码，时间步长 t 时智能体的位置，即补丁 I_t ，可以编码为当前状态 s_t ，如下所示：

$$s_t = \text{Sat2Cap}_{img}(I_t)。$$

3.3 动作-状态动态建模

与以往仅使用因果 Transformer（例如 LLMs）来预测动作的做法不同[8,33]，我们同时对动作-状态动态进行建模，且未对模型架构进行修改。

3.3.1 随机路径生成

为了收集用于训练的动作-状态序列，对于每个搜索区域，我们生成具有随机{起点， 终点}对的轨迹，如[33]所述（见图 3（b））。每个生成的序列，记为 $x_n = \{s_0, a_0, s_1, a_1, \dots, s_t, a_t, \dots, s_N, a_N\}$ ，由一系列随机选择的动作 $\{a_0, a_1, \dots, a_t, \dots, a_N\}$ 组成，这些动作探索了状态之间的可能转换。此外，我们为每个轨迹定义了真实动作转换 $\{a_0^*, a_1^*, \dots, a_t^*, \dots, a_N^*\}$ 。每个动作 a_t^* 表示一个理想的目标导向动作，它将智能体从补丁 I_t 移动到更接近目标补丁 I_{goal} 的位置。

3.3.2 用于序列建模的因果 Transformer

利用生成的轨迹，我们在一个序列建模任务上训练一个因果 Transformer，该任务 1) 预测能使智能体更接近目标位置的最优动作 a_t^* ；2) 预测在时间 t 的状态表示 s_t ，该表示取决于前一时间步的动作 a_{t-1} 。建模过程如图 3（b）所示，可表示为：

$$\hat{a}_t = \text{CausalTrans}(s_t | x_{t-1}, s_{goal}) \quad (2)$$

$$\hat{s}_t = \text{CausalTrans}(a_{t-1} | x_{t-1}, s_{goal}) \quad (3)$$

在因果 Transformer 处理之前，状态使用相对位置编码进行编码，遵循[33]

中的方法。

3.3.3 动作建模损失

我们沿用先前工作[33]中的做法，在动作-状态序列的每个时间步 t 处使用二元交叉熵损失来引导动作预测：

$$\begin{aligned}\mathcal{L}_{\text{Action}} &= \sum_{t=0}^N -(y_t \log(P_t) + (1 - y_t) \log(1 - P_t)), \\ P_t &= \text{Softmax}(\hat{a}_t).\end{aligned}\tag{4}$$

其中， N 是随机序列的长度。 P_t 是在将 x_{t-1} 和 s_{goal} 作为模型输入时，在时间步 t 对动作预测的概率。 $y_t = [y_t^{(1)}, y_t^{(2)}, \dots, y_t^{(|A|)}]$ 用于指示集合 A 中的某个动作在时间步 t 是否被视为最优动作。如果第 j 个动作能让智能体 (Agent) 更接近目标，则 $y_t^{(j)} = 1$ ，否则 $y_t^{(j)} = 0$ 。

3.3.4 状态建模损失

在不修改模型架构的情况下，我们将因果 Transformer 从仅预测动作扩展为同时预测状态和动作。为此，我们添加了一个状态建模损失。受近期世界模型研究进展的启发 [3,16,53]，我们建议使用预测的状态表示与真实状态表示之间的均方误差来引导模型学习：

$$\mathcal{L}_{\text{State}} = \sum_{t=1}^{N-1} \|\hat{s}_t - s_t\|_2^2.\tag{5}$$

请注意，这里总序列长度为 $N - 1$ ，因为我们预测时忽略了起始状态和结束状态。

最终的 DM 损失 (LDM) 是动作建模损失 ($\mathcal{L}_{\text{Action}}$) 和状态建模损失 ($\mathcal{L}_{\text{State}}$) 的组合：

$$\mathcal{L}_{\text{DM}} = \mathcal{L}_{\text{Action}} + \alpha \mathcal{L}_{\text{State}},\tag{6}$$

其中 α 是一个缩放因子。

3.4 好奇心驱动的探索

在本小节中，我们首先介绍强化学习的 Actor-Critic (演员-评论家) 流水线，它是我们方法的基础。在此基础上，我们提出了由内在奖励引导的好奇心驱动探索。

3.4.1 Actor-Critic 强化学习流水线

在好奇心探索 (CE) 期间，预训练的因果 Transformer 是冻结的。在这个阶段，我们引入了一个动作预测头 (如图 3 (c) 所示)，其中包括一个演员 (Actor)

$\pi_\theta(a|s_t)$ (策略网络) 和一个评论者 (Critic) $v_\psi(s_t)$ (价值函数), 它们遵循 Actor-Critic 强化学习流水线 [36] 并通过近端策略优化 (PPO) 进行优化。

在每个时间步 t : 1. 演员选择一个动作 $\hat{a}_t \sim \pi_\theta(a|s_t)$ 。2. 通过执行 $\hat{a}_t$, 状态转移至 s_{t+1} 并获得奖励 $\hat{r}_t$ 。3. 评论者计算价值 $v_\psi(s_t)$, 它表示从状态 s_t 开始的预期总回报。4. 演员和评论者在 PPO 算法下进行更新。

有关 PPO 智能体的详细信息, 请参见补充材料 S2。该智能体运行在因果 Transformer 的输出之上, 因此受益于在动力学建模 (DM) 期间学习到的动作-状态动态。

3.4.2 好奇心驱动的探索

对于目标导向的强化学习问题, 最直接的奖励设计通常是基于目标是否达成。然而, 这类奖励通常非常稀疏, 导致学习过程中反馈不足, 难以高效且有效地学习[28]。先前的研究尝试通过设计密集型奖励来解决这一问题, 使其在过程中易于获取。特别是, 在 AGL 领域, 现有方法采用基于当前位置与目标补丁之间距离的外部奖励来优化策略网络的动作预测头, 可表示为:

$$r_t^{\text{ex}} = \begin{cases} 1, & \text{if } \|p_{t+1} - p_{\text{goal}}\|_2^2 < \|p_t - p_{\text{goal}}\|_2^2 \\ -1, & \text{if } \|p_{t+1} - p_{\text{goal}}\|_2^2 > \|p_t - p_{\text{goal}}\|_2^2 \vee s_{t+1} \in \{x_t\} \\ 2, & \text{if } s_{t+1} = s_{\text{goal}} \end{cases} \quad (7)$$

其中 p_t 表示补丁 I_t 的位置。基于距离的奖励背后的直觉是从最小化距离中学习: 当智能体的动作缩短了与目标的距离时, 外部奖励会对其进行鼓励, 在成功到达目标位置时给予最高奖励。相反, 如果智能体远离目标或重新访问先前探索过的状态, 则会受到惩罚。然而, 当目标位置未知 (在推理期间) 时, 这种奖励难以估计, 并会对 Actor-Critic 网络产生负面影响。

为应对这一挑战, 在鼓励对环境进行探索的同时, 我们在 AGL 中引入了内在的好奇心驱动奖励。内在奖励的设计基于这样一种直觉: 当一个动作倾向于探索到一个意外的状态时, 该动作就会得到奖励。这种“意外性”的程度是根据状态观测与预测之间的差异来衡量的, 而预测则是基于 DM 中的状态动态建模得出的。依照文献[22,28], 我们基于两种不同的度量方式为 AGL 定义了好奇心驱动的内在奖励:

- 均方误差 (Mean squared error): 奖励通过预测的状态表示 ($\hat{s}_{t+1}$) 与观察到的状态表示 (s_{t+1}) 之间的均方误差来衡量:

$$r_t^{\text{in}} = \|\hat{s}_{t+1} - s_{t+1}\|_2^2 \quad (8)$$

- 余弦相似度 (Cosine similarity): 奖励通过两个特征之间的余弦相似度来衡量:

$$r_t^{\text{in}} = -\cos(\hat{s}_{t+1}, s_{t+1}) \quad (9)$$

为了将两种反馈来源 (目标和探索) 结合起来, 最终奖励是外在奖励和内在奖励的加权和, 权重由参数 β 决定:

$$r_t^{\text{CE}} = r_t^{\text{ex}} + \beta r_t^{\text{in}}. \quad (10)$$

请注意, 在乘以 β 之前, 我们将内在奖励归一化到 $[-1, 1]$ 范围内。

3.5 推理

在推理阶段, 给定以三种模态之一呈现的目标以及一个起始区域, GeoExplorer 会表征目标与环境, 并利用动作预测头确定一条长度为 M 的动作与状态轨迹 $x = \{s_0, \hat{a}_0, \dots, s_t, \hat{a}_t, \dots, s_M\}$, 该长度处于搜索预算 B 之内 (即 $M \leq B$)。

在验证时, 动作是根据 argmax 策略 (即概率最高的动作) 来选择的。为了进行路径可视化, 我们使用随机策略 (stochastic policy), 即按概率选择动作, 以展示更多可能的路径。

4. 数据与设置

4.1 数据集

我们考虑了四个 AGL 基准数据集: Masa 数据集[25]使用航拍图像作为目标。该数据集包含 1188 张图像, 其中 70% 用于训练, 15% 用于验证, 15% 用于测试[29,33]。每张图像都被视为一个搜索区域, 我们为每个区域随机生成 5 组 {起点, 目标} 对来评估模型, 从而得到 895 种测试配置。MM-GAG 数据集[33]使用不同的模态 (如文本和地面图像) 来表示目标。它包含 73 个搜索区域。xBD 数据集[15]是 xBD 数据集测试集的一个子集。遵循先前的工作[33], 保留了 800 张图像, 分别用于灾前 (xBD-pre) 和灾后 (xBD-disaster) 图像。请注意, 为了模拟真实的搜索和救援任务, 目标始终使用灾前图像 (xBD-pre) 表示, 无论搜索区域是 xBD-pre 还是 xBDdisaster。我们提出的 SwissView 数据集 (图 4) 由 Swisstopo 的 SWISSIMAGE 10 厘米分辨率图像构建而成, 包含两个不同的部分: SwissView100, 由从瑞士全境随机选取的 100 张图像组成, 从而提供了多样化的自然和城市环境; 并且还有 SwissViewMonuments 数据集, 其中包含 15 幅非典型或独特的场景图像, 例如地标和未见过的风景, 以及相应的地面图像。由于后者的对象是独一无二的, 因此它用于评估模型对未见过的目标的泛化能力, 详

细描述见补充材料 S1. 数据集详情。遵循先前的方法[29,33]，除非另有说明，GeoExplorer 仅在 Masa 数据集上进行训练，并在其他数据集上进行评估。



图 4. 来自所提出的瑞士古迹视图数据集的示例，其中包含未见过的目标。从上到下依次为：地面级图像、航拍目标区域和搜索区域。(Figure 4. Examples from the proposed SwissViewMonuments dataset with unseen targets. From top to bottom: ground-level images, aerial goal patches, and search areas.)

4.2 评估指标

我们使用成功率（SR）和到达目标的步数（SG）来进行评估。在搜索预算 B 内，如果智能体到达目标，则此次尝试视为成功。SR 定义为成功定位次数与总尝试次数的比值。SG 是路径终点与目标位置之间的曼哈顿距离。评估是在从起点到目标位置的不同距离 C 上进行的。SG 的结果在补充材料 S4.7. Step-to-the-goal (SG)评估中给出。

4.3 评估设置

我们在四种设置下评估 GeoExplorer: 1) 验证: 在与训练相同的数据集上评估模型。2) 跨域迁移: 在未见过的数据集上评估在 Masa 数据集上训练的模型，目标模态为航拍视图。3) 跨模态泛化: 目标以不同的模态呈现。4) 未见过的目标泛化: 为了评估模型对没见过目标的适应能力，我们在我们的 SwissView 数据集上评估模型，目标为航拍视图和地面图像。

4.4 实现细节

依照[33]的做法，搜索网格的维度 X 和 Y 均设为 5，从而在搜索区域内形成 25 个互不重叠的补丁。搜索预算 B 设为 10，起始点到目标点的距离从集合

$C \in \{4, 5, 6, 7, 8\}$ 中选取。根据参数分析（见补充材料 S4.1. 参数分析）， α （公式 6）设为 1， β （公式 10）设为 0.25。公式 8 是内在奖励的默认设置。我们使用预训练的 CLIP 视觉（ViT-b-32）和文本编码器[30]作为地面图像和文本描述的编码器。对于航拍图像，我们使用 Sat2Cap 卫星编码器[9]，该编码器通过对比学习进行了微调，以与 CLIP 视觉编码器对齐。GeoExplore 中使用的因果 Transformer 是预训练的 Falcon-7B 模型[1]，与[33]中的做法相同。超参数设置和所选模型遵循基线，以确保公平比较。详细描述见补充材料 S2 实现细节。

4.5 基准

我们将 GeoExplorer 与以下内容进行比较：

- 随机策略，即在每个时间步随机选择一个动作；PPO 策略[36]则根据当前观测值来选择动作。
- 决策 Transformer（DiT）[8]，这是一种通过离线最优轨迹训练的强化学习流程，该流程通过动作建模随机生成{起点,终点}对。
- AiRLoc [29]是一种基于强化学习的模型，专为单模态 AGL 任务而设计。该模型使用与目标相关的稀疏奖励来引导模型学习。
- GOMAA-Geo [33]是一种基于强化学习的通用方法，适用于多种目标模式的自动地面车辆导航任务。该方法包括基于动作建模的预训练阶段以及由基于距离的外部奖励引导的强化学习阶段。

5. 结果

5.1 评估设置中的数值结果

5.1.1 验证

我们首先在 Masa 数据集上评估模型，即用于训练的数据集。**错误!未找到引用源。**表明，GeoExplorer 在 Masa 数据集上的表现优于所有其他对比方法，尤其是在较长的搜索路径方面。具体而言，其成功率有所提升。当 $C=4$ 时为 0.0234，当 $C=8$ 时为 0.1643，与基线（GOMAA-Geo）相比。关于奖励设计，采用密集奖励的方法，如 GOMAA-Geo 或 GeoExplorer，相较于采用稀疏奖励的基线（例如 AiRLoc）具有显著优势。这突显了在 AGL 过程中提供密集且及时指导的重要性。有趣的是，尽管我们认为任务难度更大，但 C 值越大性能越高。这可归因于这些场景中配置的有限变化性，使得模型更容易过度拟合训练数据分布。（详情见补充材料 S5.1. 路径分析）

表 1. 在 Masa 数据集测试集上的数值结果。成功率（SR）在不同的起点到终点距离 C 下给出。基线的结果取自[33]。（Table 1. Numerical results on the test set of the Masa dataset.

The success ratio (SR) is reported with different start-to-goal distance C . The results of the baselines are taken from [33].)

Method	$C = 4$	$C = 5$	$C = 6$	$C = 7$	$C = 8$
Random policy	0.1412	0.0584	0.0640	0.0247	0.0236
PPO policy [36]	0.1427	0.1775	0.1921	0.2269	0.2595
AiRLoc [29]	0.1786	0.1561	0.2134	0.2415	0.2393
DiT [8]	0.2011	0.2956	0.3567	0.4216	0.4559
GOMAA-Geo [33]	0.4090	0.5056	0.7168	0.8034	0.7854
GeoExplorer	0.4324	0.5318	0.8156	0.9229	0.9497

5.1.2 跨域迁移

对于 AGL 代理而言，跨域迁移能力至关重要，因为模型通常在一个数据集上进行预训练，然后部署到未知环境中。在此，我们提供了在 Masa 数据集上训练的模型，随后部署到另外两个数据集上的结果，但目标模态仍为航拍视图。对于 MM-GAG（错误!未找到引用源。），当目标以航拍视图呈现（第一行“目标 = I”）时，GeoExplorer 表现出最佳的整体性能，平均提升了 0.0772。同样，对于 xBD 数据集（错误!未找到引用源。所示）的结果也证实了 GeoExplorer 在跨域迁移设置中的有效性，在 xBD 灾害子集上平均提升了 0.0556。请注意，这种设置极具挑战性，因为目标是以灾前图像的形式呈现的。

表 2. 在 MM-GAG 数据集上跨领域和目标模态的泛化。目标以航拍图像（“I”）、地面图像（“G”）或文本（“T”）的形式呈现。请注意，模型仅在 Masa 数据集上进行训练。

(Table 2. Generalization across domain and goal modalities on the MM-GAG dataset. The goal is presented as an aerial image (“I”), a ground-level image (“G”), or a text (“T”). Note that the models are only trained on the Masa dataset.)

Goal	Method	$C = 4$	$C = 5$	$C = 6$	$C = 7$	$C = 8$
I	Random policy	0.1412	0.0584	0.0640	0.0247	0.0236
	PPO policy [36]	0.1489	0.1854	0.1879	0.2176	0.2432
	AiRLoc [29]	0.1745	0.1689	0.2019	0.2156	0.2290
	DiT [8]	0.2023	0.2856	0.3516	0.4190	0.4423
	GOMAA-Geo [33]	0.4085	0.5064	0.6638	0.7362	0.7021
	GeoExplorer	0.4338	0.5415	0.7631	0.8369	0.8277

G	GOMAA-Geo [33]	0.4383	0.5150	0.6808	0.7489	0.6893
	GeoExplorer	0.4308	0.5138	0.7200	0.8246	0.7815
T	GOMAA-Geo [33]	0.4000	0.4978	0.6766	0.7702	0.6595
	GeoExplorer	0.4431	0.4892	0.7200	0.8062	0.7631

表 3. 在 xBD-disaster 数据集上的跨域迁移。请注意，模型仅在 Masa 数据集上进行训练，且目标始终是在灾难发生前从空中视角呈现的。(Table 3. Cross-domain transfer on the xBD-disaster dataset. Note that the models are only trained on the Masa dataset and the goal is always presented from the aerial view before the disaster.)

Method	C = 4	C = 5	C = 6	C = 7	C = 8
Random policy	0.1412	0.0584	0.0640	0.0247	0.0236
PPO policy [36]	0.1132	0.1146	0.1292	0.1665	0.1953
AiRLoc [29]	0.1201	0.1298	0.1507	0.1631	0.1989
DiT [8]	0.1012	0.2389	0.3067	0.3390	0.3543
GOMAA-Geo [33]	0.4002	0.4632	0.6553	0.7391	0.6942
GeoExplorer	0.3975	0.5025	0.7185	0.8190	0.7923

表 4. 在 SwissViewMonuments 数据集上对未见过对象的泛化能力。*corresponds 与使用预训练模型[33]所获得的结果进行比较。(Table 4. Unseen objects generalization ability on the SwissViewMonuments dataset. * corresponds to results obtained using the pretrained model[33].)

	Method	C = 4	C = 5	C = 6	C = 7	C = 8
I	GOMAA-Geo*	0.4027	0.3833	0.6267	0.7278	0.7833
	GeoExplorer	0.4133	0.5333	0.7700	0.8889	0.8833
G	GOMAA-Geo*	0.4107	0.3833	0.6367	0.7722	0.7500
	GeoExplorer	0.4160	0.5167	0.7733	0.8778	0.7833

表 5. 在 Masa 数据集上关于状态建模和奖励设计的消融研究。“MSE”和“COS”分别表示基于均方误差或余弦相似度的内在奖励。(Table 5. Ablation study on the Masa dataset on state modeling and reward design. “MSE” and “COS” denote intrinsic reward based on mean squared error or cosine similarity, respectively.)

L_{Action}	L_{State}	r_t^{ex}	r_t^{in}	C = 4	C = 5	C = 6	C = 7	C = 8
--------------	-------------	------------	------------	-------	-------	-------	-------	-------

√		√		0.4090	0.5056	0.7168	0.8034	0.7854
√	√	√		0.3978	0.4939	0.7609	0.8413	0.8648
√		√	MSE	0.3888	0.4938	0.7408	0.8615	0.9140
√	√	√	COS	0.3955	0.5385	0.8134	0.9050	0.9352
√	√	√	MSE	0.4324	0.5318	0.8156	0.9229	0.9497

5.1.3 跨模态泛化

在实际应用中，目标也可以用除航拍图像之外的其他模态来描述。**错误!未找到引用源。**中 MM-GAG 数据集的实验结果表明，在目标以地面图像（第二行“目标 = G”）和文本（第三行“目标 = T”）形式描述的情况下，GeoExplorer 仍表现出更好的泛化能力。在信息不那么直接的情况下，GeoExplorer 在短路径上的表现与基线相当，而在路径较长时显著提高了成功率（对于 $C = \{6, 7, 8\}$ ，平均值分别为 0.0690（地面图像）和 0.0610（文本））。

5.1.4 未见目标泛化

为了评估 GeoExplorer 和基线模型的泛化能力，我们在 SwissViewMonuments 数据集上设计了一个未见目标泛化实验。与之前的数据集不同，该数据集的目标补丁位置是固定的。如**错误!未找到引用源。**所示，GeoExplorer 在定位未见目标方面表现出色，尤其是在路径较长的情况下（例如，当 $C=6$ 时，使用航拍图像时提高了 0.1433，使用地面图像时提高了 0.1366）。SwissView 数据集的更多结果以及使用 SG 作为度量的评估结果见补充材料 S4. 补充实验。

5.2 消融实验

我们在 Masa 数据集上进行了消融实验：首先，在 DM 阶段改变训练目标，以分析所提出的动作-状态动态建模策略（公式 (6)）的影响。将第 2 行与第 1 行进行比较，通过添加状态建模损失，SR 平均提高了 0.0277，这表明状态转换建模对动作预测的有效性，尤其是在较长距离的情况下。在没有状态建模的情况下添加内在奖励也显示出改进（平均提高 0.0357，第 3 行和第 1 行），这表明即使不准确的状态预测，即使没有明确的监督，仍能为探索提供有用的信息。带有动作-状态动态建模的 GeoExplorer 表现出最佳的整体性能。通过学习状态建模，SR 平均提高了 0.0507（第 5 行和第 3 行）。我们还测试了不同奖励设计的配置。结果表明，两种奖励设计的性能相似，平均 SR 差异为 0.0130。我们注意到在短路径上性能略有下降（第 1 行和第 2/3 行）。对于较短的路径，智能体到达目标的步数有限，留给探索的空间较小，这可能导致绕路。此外，由于历史状态

观测有限，在短路径上进行状态建模可能会不准确。

5.3 内在奖励能促进探索吗？

5.3.1 探索能力的可视化




图 5. GeoExplorer 展现出了强大、多样且与内容相关的探索能力。在每个搜索区域给定一对 {起点 (◦), 终点 (△)} 后，模型会生成四次试验，采用随机策略（第 3.5 推理节），以四种不同颜色随机显示。(a) 距离不同的相似 {起点, 终点} 对。尽管距离估计存在困难，但 GeoExplorer 的探索能力依然保持强大且多样。(b) 同一搜索区域内的 {起点, 终点} 对位置互换。GeoExplorer 的探索具有适应性和鲁棒性，不受搜索方向影响，对目标内容的探索保持一致。(c) 在 Masa 测试集中，当距离 $C = 4$ 和 $C = 8$ 时，两种模型生成的所有路径访问过的区域统计。数字表示每个区域的访问次数。GeoExplorer 实现了更全面的探索，覆盖了整个搜索区域。(Figure 5. GeoExplorer shows robust, diverse, and content-related exploration ability. Given a pair of {start (◦), goal (△)} per search area, models generate four trials with stochastic policy (Sec. 3.5), randomly shown in four different colors. (a) Similar {start, goal} pairs with different distance. Despite the difficulties of estimating distance, GeoExplorer’s exploration ability maintains robust and diverse. (b) Reversed {start, goal} pairs in the same search area. GeoExplorer’s exploration is adaptive and robust to goal content irrespective of the search direction. (c) Statistics of visited patches by all generated paths for both models when the distance $C = 4$ and $C = 8$ in Masa test set. Numbers denote the counts of visits per patch. GeoExplorer develops a more comprehensive exploration covering the search area.)

为了更好地理解 GeoExplorer 和基准模型 GOMAA-Geo 的探索能力，我们在图 5 中展示了生成的路径。在图 5 (a) 中，我们比较了来自两个不同搜索区域的具有相似语义内容的 {起点, 终点} 对。当起点和终点之间的距离较短且易于估计时，GOMAA-Geo 能够成功地以最短路径到达终点（上例）。然而，在下例中，视觉上相似的起点和终点位于图像的不同部分，GOMAA-Geo 难以准确地定位终点，因为它更难估计可能的距离。相比之下，GeoExplorer 则成功了，它

利用其动作状态建模能力来区分可能的路径。在图 5(b)中,我们反转了{起点, 终点} 的位置以评估模型的鲁棒性。GOMAAGeo 未能保持鲁棒性, 而 GeoExplorer 则得益于其探索能力, 无论搜索方向如何都能成功到达目标。图 5(c)所示的已访问区域分布更全面地展示了探索能力: 当 $C = 4$ 时, GOMAAGeo 在搜索区域中心部分的已访问区域仅占 20.08%, 而 GeoExplorer 将这一比例提高到了 30.79%, 表明其探索更为全面。这些发现进一步证实了 GeoExplorer 具有强大、多样且与内容相关的探索能力。

5.3.2 好奇心模式分析

我们对由好奇心驱动的内在此奖励进行了深入分析。在图 6(b)中我们展示了由我们的模型检索到的四条路径及其对应的平均累积内在奖励(颜色与路径相同)。不出所料, 我们观察到访问多样图像内容(例如, 绿色和蓝色轨迹中的森林、城市和河流)的轨迹比仅穿越森林区域(例如黄色轨迹)的轨迹具有更高的平均内在奖励。图 6(c)展示了每个区域的探索分数。请注意, 为了可视化, 我们对内在奖励进行了归一化处理。好奇心奖励自然密集且与内容相关。内在奖励较高的区域更“有趣”, 即这些区域的语义内容很难从周围的区域预测出来。例如, 右列示例中得分最高的区域描绘了从森林到城市环境的过渡。这些结果表明, 好奇心驱动奖励提供了密集、目标无关且与内容相关的指导, 增强了 GeoExplorer 的探索能力。




图 6. 好奇心驱动的内禀奖励为 GeoExplorer 提供了密集、目标无关且内容相关的指导，以增强其探索能力。来自 MM-GAG 数据集针对多种目标模态的示例。(a) 每个示例（列）的目标以不同的模态表示。(b) 四次试验以及路径上的平均内在奖励。(c) 四次试验在补丁级别的内禀奖励。(Figure 6. Curiosity-driven intrinsic rewards provide dense, goal-agnostic, and content-related guidance to enhance the exploration ability of GeoExplorer. Examples from the MM-GAG dataset targeting multiple goal modalities. (a) The goal of each example (column) is represented in different modalities. (b) Four trials, as well as average intrinsic rewards along the paths. (c) Average intrinsic reward from four trials at the patch level.)

6. 结论

自适应主动探索是迈向在现实世界中开展搜索救援行动的自主地面机器人（AGL）发展的重要一步。在本文中，我们提出了 GeoExplorer，这是一种 AGL 代理，它通过结合目标导向和好奇心驱动的引导，并基于全面的环境建模来探索搜索区域。好奇心驱动奖励是目标无关的，通过利用状态预测与观察之间的差异来提供密集且可靠的反馈，从而鼓励探索。在四个 AGL 基准上的大量实验

和分析表明，GeoExplorer 超过了最先进的方法，并且在未见过的目标和环境表现出显著的可转移性，突显了其由内在好奇心驱动的稳健、通用、内容感知的探索能力。

致谢

我们感谢匿名审稿人提出的富有建设性和深思熟虑的意见。我们感谢高思林、瓦伦丁·加贝夫、徐畅、菲利普·多姆、西里耶尔·蒙塔里奥尔和塞皮德·马穆勒对本研究早期版本提供的有益反馈。我们感谢国家留学基金委和洛桑联邦理工学院科学种子基金的支持，以及洛桑联邦理工学院与瑞士安盛集团运营公司之间“利用高分辨率遥感技术变革商业保险承保业务”项目的资助。AB 感激地感谢瑞士国家科学基金会（编号：215390）、Innosuisse（PFFS-21-29）、洛桑联邦理工学院成像中心、索尼集团公司以及 Meta 大语言模型评估研究资助金的支持。

补充材料

补充材料的组织结构如下：

- 数据集详情（附录 S1）
- 实现细节（附录 S2）
- AGL 与相关任务的比较（附录 S3 节）
- 补充实验： 参数分析、不同预算和更大网格尺寸下的实验、以步数到目标为指标的评估以及补充结果（附录 S4）
- 补充分析： 路径分析、额外的可视化样本以及失败案例分析（附录 S5）
- 讨论： 局限性与未来工作（附录 S6）

S1. 数据集详情

S1.1. 马萨诸塞州建筑（Masa）数据集

数据收集： 马萨诸塞州建筑（Masa）数据集[25]包含 1188 张波士顿地区的高分辨率图像。建筑轮廓标注是通过将来自 OpenStreetMap 项目的数据栅格化获得的。

数据集构成： 该数据集按 70%用于训练（832 张图像）、15%用于测试和评估（178 张用于验证，179 张用于测试）[29,33]进行划分。每张图像或搜索区域被构建成一个 5×5 的搜索单元网格，每个网格单元为 300×300 像素。在训练过程中，通过右上角和左右翻转进行数据增强，每个搜索区域允许 25 个起始位置和 24 个可能的目标位置，从而产生约 200 万条独特的训练轨迹。对于测试和验证，仅针对每个起始-目标距离和每个搜索区域随机选择一个固定配置，确保有 895 条固定的测试轨迹。

S1.2. MM-GAG 数据集

MM-GAG 数据集[33]的构建旨在解决现有主动地理定位（AGL）数据集存在的局限性，这些数据集通常缺乏精确的坐标标注以及跨多种模态的有意义的目标表示。

多模态目标表示： 与许多仅关注空对空或空对地定位的现有数据集不同，MM-GAG 引入了多模态目标表示：

- 航空影像，
- 地面图像，
- 自然语言描述。

数据收集： MM-GAG 数据集是通过以下方式构建的：从智能手机中收集高质量的地理标记图像来自不同地点的设备，图像已过滤，从而形成了 73 个不同

的搜索区域。请注意，通过在原始论文¹中提供的链接，我们仅找到 65 个搜索结果领域。为确保公平比较，我们对所提出的方案进行了评估。在第 S4 节中，采用了该原始论文中提供的方法和预训练基线模型。对于每张 73 张地面图像，以每像素 0.6 米的分辨率获取了高分辨率卫星图像补丁。从这些补丁中，构建了 5×5 的搜索网格，每个网格单元为 256×256 像素。为了生成文本目标描述，使用 LLaVA-7B [20] 自动为每张地面图像生成标题。标题提示经过精心设计，以确保描述简洁且相关。

数据集构成：通过在 73 个搜索区域内随机选取起始点和目标点来选择轨迹，以确保涵盖各种不同的搜索场景。对于每个区域，针对每个预定义的距离类别选择五组 {起始点, 目标点}，从而在每个起始点到目标点的距离类别下产生总共 365 条评估轨迹。

S1.3. xBD 数据集

xBD 数据集[15]是一个用于灾害分析的大规模航拍图像数据集。它包含在各种自然灾害（如野火、洪水和地震）发生前（xBD-pre）和发生后（xBD-disaster）拍摄的图像。

数据收集：原始 xBD 数据集的图像来自 Maxar/DigitalGlobe 开放数据计划²，该计划为重大危机事件提供高分辨率卫星图像。该数据集包含 19 次自然灾害的图像，覆盖 45361.79 平方千米的受灾区域。共收集了 22068 幅图像，涵盖 850736 个人工标注的建筑物多边形。

数据集构成：对于 AGL 的特定任务，从原始数据集中选取了 800 个双时相搜索区域（灾难发生前的一张图像和灾难发生后的一张图像）。每个搜索区域对应一个 5×5 的搜索网格，每个网格单元为 300×300 像素。通过在每个起始点到目标点的距离上随机采样 5 对起始点和目标点，从而获得轨迹，这导致每个起始点到目标点的距离有 4000 条评估轨迹。

S1.4. SwissView 数据集

数据收集：SwissView 数据集由两个互补的组件构成：SwissView100 和 SwissViewMonuments。对于 SwissView100，从 Swisstopo 的 SWISSIMAGE 10 cm 数据库³中随机抽取了覆盖瑞士全境的 100 幅图像。图像的空间分布情况见图 S2。原始图像的空间分辨率为每像素 0.1 米，尺寸为 10000×10000 像素，将其下采样至每像素 0.6 米的分辨率，得到 1500×1500 像素的图像。这些下采样后的图像随后被分割成 5×5 的块，每块尺寸为 300×300 像素。对于

¹ <https://huggingface.co/datasets/MVRL/MM-GAG/tree/main>

² <https://www.digitalglobe.com/>

³ <https://www.swisstopo.admin.ch/fr/orthophotos-swissimage-10-cm>

SwissViewMonuments 数据集，其流程相同，只是图像的选择有所不同。该数据集的这一部分精心挑选了瑞士 15 个具有独特建筑或景观的特定区域。我们考虑了两类目标：1) 对象的独特性：地标或可定位的建筑；2) 位置和场景的独特性：未见过的场景类别。例如，生成的数据集包含来自著名建筑（如大教堂和城堡）以及罕见景观（如冰川）的图像。除了搜索区域的航拍图像外，我们还提供了相应的地面图像及其与航拍图像对应的地理位置。SwissViewMonuments 数据集的几个示例见图 S1。




图 S1. 来自所提议的 SwissViewMonuments 数据集的更多示例，其中包含未见过的目标。从上到下依次为：以地面视角呈现的目标图像、以航拍视角呈现的目标图像以及搜索区域。(Figure S1. Additional examples from the proposed SwissViewMonuments dataset with unseen targets. From up to down: goal presented as ground-level images, goal presented in aerial view, and the search areas.)

数据集统计：所选区域的位置也在图 S2 中给出。来自 SwissView100 数据

集的样本（以红色显示）分布在该区域，而来自 SwissViewMonuments 数据集的样本（以蓝色显示）则选自城市、旅游景点和自然保护区。

数据集构成：为了生成瑞士景观 100 子集的轨迹，我们采用了与生成其他数据集类似的方法，即为每条轨迹和每个起始点到目标点的距离随机生成 5 个 {起始点目标点} 对，从而在考虑的每个距离上得到 500 条轨迹。相比之下，对于瑞士景观地标子集，我们为每个空地提供 25 个平移后的航拍视角（总共 15×25 个样本），将目标点固定在 5×5 网格中的所有位置。对于每个指定的起始点到目标点的距离 $C \in \{4, 5, 6, 7, 8\}$ ，我们从每个样本中随机选择一个满足给定距离的起始点，相对于固定的目标点。对于在给定距离上无法找到任何有效起始点的目标点位置，其样本将从该距离的评估中排除。这一过程分别在距离 C 为 $\{4, 5, 6, 7, 8\}$ 时，产生了 $\{375, 360, 300, 180, 60\}$ 种配置。




图 S2. 瑞士视图数据集图像的地理分布。红色点表示从瑞士视图 100 子集随机抽取的 100 张图像的位置，而蓝色点则代表瑞士视图古迹子集中的图像。(Figure S2. Geographic distribution of the images from the SwissView dataset. Red points indicate the locations of the 100 randomly sampled images from the SwissView100 subset, while blue points represent the images from the SwissViewMonuments subset.)

S2 实现细节

本节概述了实现细节，包括用于文本、地面级和航拍图像编码的预训练模型，以及用于动作状态建模的因果 transformer。请注意，除了我们模型中的动作状态动态建模和好奇心驱动组件外，实现和训练参数与 Sarkar 等人[33]的工作中所述的一致，该工作是本研究的基准。

文本和地面图像编码器：为了对目标的文本描述和地面图像进行编码，我们使用了 CLIP 模型[30]中的预训练编码器，所用的预训练权重与[33]中相同，可在 Hugging Face⁴ 上获取。具体来说，视觉编码器是视觉变换器（ViT-b-32），而文本编码器基于 BERT 架构，这两者通过对比学习在共享的多模态嵌入空间中对齐。在训练 Geo-Explorer 模型期间，这些编码器保持不变。

航空图像编码器：航空图像通过 Sat2Cap 卫星编码器[9]进行处理，该编码器经过微调以使其特征表示与 CLIP 嵌入空间对齐。对齐过程采用对比学习和 InfoNCE 损失函数[27]，利用大规模的航空图像与地面图像配对数据集。需要注意的是，在微调航空图像编码器的过程中，CLIP 图像编码器保持不变。这种对齐确保了从航空图像中提取的特征与文本描述和地面图像的特征处于相同的表示空间。我们使用与参考文献[33]相同的预训练权重作为 Sat2Cap 的权重，这些权重可在 Hugging Face⁵上获取。

Causal Transformer：对于用于序列动作和状态预测的 Causal Transformer，我们采用预训练的 Falcon-7B 模型[1]。预训练权重可在 Hugging Face⁶ 上获取。我们遵循 GOMAAGeo [33]中介绍的多模态投影层，将视觉和语言模态对齐到 Falcon-7B 模型的潜在空间。此外，每个状态表示中都加入了相对于图像左上角位置的相对位置编码，使模型能够编码观测到的航拍图像之间的空间关系。需要注意的是，与 Sarkar 等人的工作[33]的主要区别在于，我们的方法是同时预测状态和动作，而不仅仅是预测动作。不过，整体结构保持不变。因果 Transformer 使用 $1e-4$ 的学习率、1 的批处理大小以及 Adam 优化器训练 300 个周期。我们遵循 GOMAA-Geo [33]中的设置以确保公平比较。

PPO：在好奇心驱动探索(CE)阶段，我们在冻结的预训练 Causal Transformer 之上引入了一个动作预测头。由于 Causal Transformer 本身并不直接建模决策策略，因此添加动作预测头至关重要，因为它使系统能够明确地从学习到的状态表示映射到要采取的具体动作。动作预测头采用 Actor-Critic 框架实现，并使用近端策略优化(PPO)[36]进行优化。该框架包含一个负责策略学习的演员(Actor)网络 $\pi_{\theta}(a|s_t)$ ，并且有一个评论者(Critic)网络 $v_{\psi}(s_t)$ ，用于评估从状态 s_t 出发的预期总奖励。如图 S3 所示，行为网络和评估器网络均采用具有三个隐藏层的多层感知机(MLP)实现。每个隐藏层之后都接有一个 $\tanh$ 激活函数。行为网络的最终层包含一个 softmax 激活函数，用于输出动作的概率分布，从而确保选择有效的动作。评估器网络输出一个标量值，代表估计的价值函数。

⁴ <https://huggingface.co/openai/clip-vit-base-patch32>

⁵ <https://huggingface.co/MVRL/Sat2Cap>

⁶ <https://huggingface.co/openai/clip-vit-base-patch16>




图 S3. Actor-Critic (演员-评论家) 网络 (动作预测头) 的模型架构 (Figure S3. Model architecture of the actor-critic network (action prediction head))

在每个时间步 t (它指定了时间索引在 $[0, T]$ 范围内), 基于状态表示 s_t , PPO 的学习过程可以描述为:

- (1) 演员 (Actor): 选择一个动作 $\hat{a}_t \sim \pi_\theta(a|s_t)$, 其中 $a \in \mathcal{A}$ 是可用动作集中的一个动作。
- (2) 智能体 (Agent): 在环境中执行该动作, 并获得新状态 s_{t+1} 和奖励 r_t^{CE} 。
- (3) 价值 (Value): 即来自状态 s_t 的总奖励, 由评论者 (Critic) $v_\psi(s_t)$ 计算得出。
- (4) 回报 (Return), 即从状态 s_t 采取动作 $\hat{a}_t$ 所获得的总奖励, 计算如下:

$$q(s_t, \hat{a}_t) = \sum_{t'=t}^T E_{\pi_\theta}[r_{t'}^{CE} | s_t, \hat{a}_t] = r_t^{CE} + \gamma r_{t+1}^{CE} + \dots + \gamma^{T-t+1} r_{T-1}^{CE} + \gamma^{T-t} v_\psi(s_T) \quad (11)$$

- (5) 优势函数 (Advantage function) A_t 被计算出来, 用以估算动作 $\hat{a}_t$ 相比于状态 s_t 的平均性能预期表现优劣程度:

$$A_t = q(s_t, \hat{a}_t) - v_\psi(s_t) \quad (12)$$

- (6) 更新演员和评论者。

我们使用 PPO 损失函数同时更新演员 (Actor) 和评论者 (Critic) 网络，该损失函数主要由三个部分组成：

演员损失 (剪切代理目标函数)：它通过比较旧策略与更新后策略的概率，将策略变化的幅度约束在一个较小的范围内：

$$\mathcal{L}_{\text{Actor}} = \min \left\{ \frac{\pi_{\theta}}{\pi_{\theta, \text{old}}} A_t, \text{clip} \left(1 - \epsilon, 1 + \epsilon, \frac{\pi_{\theta}}{\pi_{\theta, \text{old}}} \right) A_t \right\} \quad (13)$$

评论者损失 (Critic loss)：用于衡量模型对预期回报的预测准确度：

$$\mathcal{L}_{\text{Critic}} = (v_{\psi}(s_t) - q(s_t, \hat{a}_t))^2 \quad (14)$$

熵正则化 (Entropy regularization)：通过防止过早收敛到次优策略，鼓励策略进行探索：

$$\mathcal{H}[\pi_{\theta}](s_t) = - \sum_a \pi_{\theta}(a | s_t) \log \pi_{\theta}(a | s_t) \quad (15)$$

用于优化的最终损失函数为：

$$\mathcal{L}_{\text{PPO}} = \mathbb{E}[-\mathcal{L}_{\text{Actor}} + \omega \mathcal{L}_{\text{Critic}} + \rho \mathcal{H}] \quad (16)$$

其中， ω 和 ρ 是超参数，用于控制策略学习、价值估计和探索之间的平衡。

我们选择的超参数与基线模型[33]保持一致。学习率设为 $1\text{e-}4$ ，批量大小为 1。使用 Adam 优化器对模型进行 300 个周期的训练。超参数 α 和 β 的值分别设为 0.5 和 0.01。裁剪比 ϵ 选为 0.2，折扣因子 γ 对所有实验均设为 0.99。与 [33] 相同，每 4 个周期的策略训练后，将 π_{θ} 的参数复制到 $\pi_{\theta, \text{old}}$ 。在 CE 阶段，将补丁调整为 224×224 并进行归一化处理。

S3. AGL 与相关工作的对比

以下部分对四个相关任务进行了比较：主动地理定位、视觉地理定位、跨视角地理定位和视觉导航。它突出了它们的特点和差异，以及相关的挑战。

S3.1. 主动地理定位

主动地理定位旨在通过一系列视觉航拍观测来探索环境从而定位目标[29]。在诸如搜索与救援[29,33]等应用中，这一任务尤为重要，因为高效的探索对于成功至关重要。与仅依赖独特且静态观测的视觉地理定位[51]不同，主动地理定位需要移动代理来优化位置估计并最终达到目标。通常，目标可以通过不同的模态来指定，例如图像或文本描述[29,33]。强化学习常被用于定义代理的探索策略，引导其朝着预定义的目标前进。

S3.2. 视觉地理定位

视觉地理定位任务[51]与主动地理定位任务相关，两者都旨在根据给定图像确定位置。然而，主动地理定位使用代理探索环境以精确定位并达到目标，而视觉地理定位仅依赖于单个输入，例如图像或视频帧，无需代理移动[2,42]。通过将输入图像与现有地理标记图像数据库进行比较，通常借助图像检索技术[4,5]来估计输入图像的位置。视觉地理定位可在各种环境中运行，从特定街道等小范围区域[2]到大型城市环境[4]，这取决于所使用数据集的范围。常见应用包括移动设备定位[7]或利用街景数据的自动驾驶汽车[10]。

S3.3. 跨视角地理定位

跨视角地理定位任务旨在通过检索其对应的带有地理标签的航拍图像来定位地面图像[47,52,54]。特别是，细粒度的跨视角地理定位[13,38,39,44,49]需要估计查询地面图像在航拍图像上的 3 个自由度(DoF)姿态，这与 AGL 设置类似。尽管两者相关，但跨视角地理定位需要对搜索区域有全面的访问权限以进行匹配，而 AGL 从一开始仅向代理提供搜索区域的部分可见性，并且仅沿着探索轨迹进行观察。

S3.4. 视觉导航

视觉导航[3,18,37]与视觉地理定位类似，因为这两项任务都涉及智能体探索其环境以达到预定义的目标。然而，与在鸟瞰视角环境（即空中环境）中工作的视觉地理定位不同，视觉导航通常在地面环境中运行。尽管存在相似之处，但主动地理定位与视觉导航相比具有其独特的挑战。一个关键的区别在于，在主动地理定位中，目标可能无法提前让智能体看到，甚至可能以与智能体观察不同的模态呈现，这引入了一定程度的不确定性和复杂性。此外，由于每一步观察的空间范围更大，环境可能在两次动作之间突然发生变化，因为智能体可以迅速从一种地形过渡到另一种地形（例如从城市地区过渡到森林地区）。相比之下，视觉导航中智能体所处的环境更具局部性，这使得位置估计更准确，导航也更容易。

S3.5. 视觉语言导航

视觉语言导航（VLN）[14,45]，尤其是空中视觉语言导航[12,21]，与自主目标定位（AGL）相关联，因为这两项任务都为智能体提供了多模态的引导，使其在环境中到达目标。与 AGL 不同，VLN 在观察和行动方面都在连续空间中进行导航，这带来了额外的挑战。然而，AGL 与 VLN 相比也有其独特的挑战。由于 VLN 假定指导者知晓目标位置，自然语言指令在整个导航过程中都很详细，并且通常与智能体的动作相对应（例如，“向右转”）。而在 AGL 中，仅提供目标信息作为引导，这使得在目标导向的强化学习环境中，由于奖励稀疏和累积误

差的存在，任务设置更具挑战性。此外，VLN 的主流方法基于序列建模和预测，这与 AGL 的强化学习流程不同。

S4. 补充实验

S4.1. 参数分析

损失权重 α 的影响：我们使用损失权重 α 来平衡动作建模损失和状态建模损失的贡献。为了评估不同消融实验的有效性，我们在 Masa 数据集的测试集上，按照主论文第 3.3 节所述步骤，随机生成每个时间步都采用最优动作的动作-状态轨迹。然后，我们评估模型在轨迹每一步预测最优动作的能力。我们使用随机种子以确保在每次测试中所有方法测试的轨迹相同，并在 5 次不同的测试中评估模型。每次测试的动作预测准确率以及 5 次测试的平均预测准确率见[错误!未找到引用源。](#)除了测试 1 之外，在大多数测试中，添加状态建模损失都带来了更好的动作预测性能，这证实了状态和动作转换之间存在内在联系，并且相互动态影响。当 $\alpha=1$ 时，模型的整体性能最佳，比仅使用动作建模损失 ($\alpha=0$) 的基线模型提高了 0.0271。

奖励权重 C 的影响：我们还通过使用奖励权重 β 来控制内在奖励对最终奖励的影响。表 S2 中的结果表明，应当在引导智能体朝向目标的外在奖励与鼓励智能体探索环境的内在好奇心奖励之间取得良好的平衡。实证结果表明，当 $C=0.25$ 时，智能体在外在目标的引导和内在好奇心的驱动之间达到了最佳平衡。

表 S1. Masa 数据集测试集上损失权重 α 的参数分析。报告了 DM 阶段的动作预测准确率。 $\alpha = 0$ 表示仅使用动作建模损失的基线 (Table S1. Parameter analysis of loss weight α on the test set of the Masa dataset. The action prediction accuracy is reported for the DM stage. $\alpha = 0$ denotes the baseline with action modeling loss only.)

α	Test 1	Test 2	Test 3	Test 4	Test 5	Average
0	0.6056	0.1883	0.0838	0.6953	0.1429	0.3432
0.5	0.5162	0.1708	0.1133	0.7034	0.1429	0.3293
1	0.5777	0.2602	0.0407	0.8299	0.1429	0.3703
2	0.5687	0.2179	0.0064	0.8055	0.1524	0.3502

表 S2. Masa 数据集测试集上奖励权重 β 的参数分析。 $\beta = 0$ 表示仅使用外部奖励的基线 (Table S2. Parameter analysis of reward weight β on the test set of the Masa dataset. $\beta = 0$ denotes the baseline with extrinsic reward only)

β	$C = 4$	$C = 5$	$C = 6$	$C = 7$	$C = 8$
0	0.3978	0.4939	0.7609	0.8413	0.8648

0.25	0.4324	0.5318	0.8156	0.9229	0.9497
0.5	0.3597	0.4849	0.7687	0.9073	0.9587
1	0.3988	0.4983	0.7542	0.9028	0.9352

S4.2. xBD 数据集的结果

我们在**错误!未找到引用源。**中展示了 xBD 数据集的补充结果。结果表明，GeoExplorer 在两个子集之间存在较小的性能差距（平均为 0.0149），这表明了该模型的泛化能力。

S4.3. SwissView100 数据集的结果

SwissView 数据集包含两个子集：用于未见过的目标泛化评估的 SwissViewMonuments 和用于跨域迁移评估的 SwissView100。我们在主论文中展示了前者的评估结果，在本节中展示后者的结果。如前所述，SwissView100 数据集的测试设置与 MM-GAG Aerial 和 xBD 数据集上的跨域迁移设置相同：模型仅在 Masa 数据集上进行训练，目标以航拍视角呈现。如**错误!未找到引用源。**所示，模型在不同数据集之间面临领域偏移：与在 Masa 数据集上的表现相比，两种方法的性能平均下降了 0.0375。然而，GeoExplorer 仍优于基线模型，表明其具有更好的跨域迁移能力。

S4.4. MM-GAG 数据集的补充结果

如 S1. 数据集详情所述，通过论文提供的链接仅找到 65 个搜索区域。为确保公平比较，我们在相同的测试配置下评估了 GeoExplorer 和预训练的 GOMAA-Geo，并将结果报告在**错误!未找到引用源。**中。我们还报告了原始论文中 GOMAA-Geo 的性能以供参考。结果表明，与 65 个和 73 个搜索区域的情况类似：GeoExplorer 在短路径上实现了与基线相当的性能，而在路径较长时显著提高了 SR。

S4.5. 不同搜索预算下的探索

搜索预算 (B) 是 AGL 中的一个重要因素。为了进一步阐明其对探索行为的影响，在图 S4 中，我们比较了 GeoExplorer 和基线模型 GOMAA-Geo 在不同 B 值下的表现，此时 C = 6。不出所料，随着 B 值的增加，两个模型的性能均有所提升，因为对错误的容忍度更高。更有趣的是，随着 B 值的增加，GeoExplorer 的优势更加明显 (B = 6 时为 0.0603，而 B = 12 时为 0.0850)，因为它在定位过程中允许更多的探索。




图 S4. 当 $C = 6$ 时, GeoExplorer 与基准模型在不同搜索预算下的比较 (Figure S4. Comparison between GeoExplorer and the baseline model with varying search budget when $C = 6$.)

S4.6. 大网格尺寸下的探索

我们以 10×10 的网格大小对 GeoExplorer 和 GOMAAGeo [33] 进行比较, 其中 $C = \{14 - 18\}$, 为更长的路径提供了更多的变化性。如错误!未找到引用源。所示, GeoExplorer 一直表现出改进, 尤其是在更长的路径上, 这与在 5×5 网格大小上测试的结果一致。请注意, 所有模型都针对 10×10 的网格大小进行了重新训练。

S4.7. Step-to-the-goal (SG) 评估

除了在 AGL 中常用的度量指标成功率 (SR) 之外, 我们还在 SwissView 数据集上提供了步至目标 (SG), 用于评估路径终点与目标位置之间的曼哈顿距离。错误!未找到引用源。中的结果表明, GeoExplorer 提高了成功率, 并使智能体更接近目标。

表 S3. 在 xBD-pre 和 xBD-disaster 数据集上的跨领域迁移。请注意, 模型仅在 Masa 数据集上进行训练, 并且对于这两个数据集, 目标始终是在灾难发生前从空中视角呈现。

(Table S3. Cross-domain transfer on the xBD-pre and xBD-disaster datasets. Note that the models are only trained on the Masa dataset and the goal is always presented from the aerial view before the disaster for both datasets.)

Method	Evaluation using xBD-pre Dataset					Evaluation using xBD-disaster Dataset				
	C = 4	C = 5	C = 6	C = 7	C = 8	C = 4	C = 5	C = 6	C = 7	C = 8
Random policy	0.1412	0.0584	0.0640	0.0247	0.0236	0.1412	0.0584	0.0640	0.0247	0.0236
PPO policy [36]	0.1237	0.1262	0.1425	0.1737	0.2075	0.1132	0.1146	0.1292	0.1665	0.1953

AiRLoc[29]	0.1191	0.1254	0.1436	0.1676	0.2021	0.1201	0.1298	0.1507	0.1631	0.1989
DiT [8]	0.1132	0.2341	0.3198	0.3664	0.3772	0.1012	0.2389	0.3067	0.3390	0.3543
GOMAA-Geo[33]	0.3825	0.4737	0.6808	0.7489	0.7125	0.4002	0.4632	0.6553	0.7391	0.6942
GeoExplorer	0.3973	0.4990	0.7328	0.8390	0.8363	0.3975	0.5025	0.7185	0.8190	0.7923

表 S4. 在 SwissView 数据集的 SwissView100 子集上进行的跨领域迁移评估 (Table S4. Cross-domain transfer evaluation on the SwissView100 subset of SwissView dataset)

Method	C = 4	C = 5	C = 6	C = 7	C = 8
GOMAA-Geo*	0.4100	0.5000	0.6580	0.7780	0.6880
GeoExplorer	0.4020	0.5120	0.7660	0.9040	0.8800

表 S5. MM-GAG 数据集上 65 个搜索区域的补充结果。目标以航拍图像 (“I”)、地面图像 (“G”) 或文本 (“T”) 的形式呈现。原论文中的结果以灰色显示, *denotes 使用论文提供的预训练模型在相同配置下得到的结果。(Table S5. Supplementary results on the MM-GAG dataset with 65 search areas. The goal is presented as an aerial image (“I”), a ground-level image (“G”), or a text (“T”). Results from the original paper are in gray and *denotes the results on the same configurations using pretrained model provided by the paper.)

Goal	Method	C = 4	C = 5	C = 6	C = 7	C = 8
I	GOMAA-Geo [33]	0.4085	0.5064	0.6638	0.7362	0.7021
	GOMAA-Geo*	0.4246	0.4769	0.7385	0.7662	0.6369
	GeoExplorer	0.4338	0.5415	0.7631	0.8369	0.8277
G	GOMAA-Geo [33]	0.4383	0.5150	0.6808	0.7489	0.6893
	GOMAA-Geo*	0.4585	0.4554	0.6646	0.7169	0.6708
	GeoExplorer	0.4308	0.5138	0.7200	0.8246	0.7815
T	GOMAA-Geo [33]	0.4000	0.4978	0.6766	0.7702	0.6595
	GOMAA-Geo*	0.4277	0.5015	0.6523	0.7538	0.6677
	GeoExplorer	0.4431	0.4892	0.7200	0.8062	0.7631

表 S6. GeoExplorer 与在 Masa 数据集上使用更大网格尺寸的基线模型的比较。请注意, 所有方法均在 10×10 网格尺寸上进行训练。**corresponds 使用官方代码 [33] 重新训练模型所获得的结果。(Table S6. Comparison between GeoExplorer and the baseline model with larger grid size on the Masa dataset. Note that all the methods are trained on the 10×10 grid size. **corresponds to results obtained from the re-trained model using official code [33].)

Method	C = 14	C = 15	C = 16	C = 17	C = 18
GOMAA-Geo**	0.2603	0.2704	0.2916	0.2413	0.2201

GeoExplorer	0.2883	0.3117	0.3352	0.3073	0.3151
-------------	--------	--------	--------	--------	--------

表 S7. 在 SwissViewMonuments 数据集上对未见过对象泛化能力的逐步趋近目标评估。

*corresponds 对比来自预训练模型[33]的结果。(Table S7. Step-to-the-goal evaluation of unseen objects generalization ability on the SwissViewMonuments dataset. * corresponds to results obtained from the pretrained model[33])

	Method	C = 4	C = 5	C = 6	C = 7	C = 8
I	GOMAA-Geo*	2.16	1.91	1.18	0.93	0.77
	GeoExplorer	2.08	1.56	0.65	0.28	0.30
G	GOMAA-Geo*	2.19	1.81	1.07	0.69	0.77
	GeoExplorer	2.14	1.51	0.64	0.29	0.70

S5. 补充分析

S5.1. 路径分析

我们通过追踪基线模型和 GeoExplorer 访问过的区域来深入分析模型的探索能力。在图 S5 (a) 中, 我们统计了来自 Masa 测试集的 895 条路径在真实目标位置、GOMAAGeo 和 GeoExplorer 中的终点位置。结果表明: 1) 当 $C = 4$ 时, 目标位置在搜索区域内分布更均匀, 而当 $C = 8$ 时, 配置则较为有限。这或许可以解释为何通常在 $C = 8$ 时性能更高。随着轨迹的延伸和探索的进行, 智能体可能会根据训练数据的分布推断出目标很可能位于角落。2) 基线模型的路径终点分布表明其倾向于访问边缘区域 (当 $C = 4$ 时, 84.36% 的路径终点位于边缘区域), 而 GeoExplorer 则改善了对内部区域的探索。图 S5 (b) 中显示的访问区域分布证实了这一观察结果: 当 $C = 4$ 时, GOMAA-Geo 只有 20.08% 的访问区域位于内部, 而 GeoExplorer 将这一比例提高到了 30.79%。这一发现表明, GeoExplorer 通过更出色的环境探索能力提升了在 AGL 基准测试中的表现。




图 S5. GeoExplorer 倾向于在搜索区域内探索更多的区域，尤其是内部区域。(a) 路径终点统计。我们统计了 Masa 数据集测试集中 895 条路径在 $C=4$ 和 $C=8$ 时，真实情况（目标位置）、GOMAA-Geo 和 GeoExplorer 的路径终点位置。(b) 路径访问统计。我们统计了 Masa 数据集测试集中 895 条路径在 $C=4$ 和 $C=8$ 时，GOMAA-Geo 和 GeoExplorer 访问的所有区域。(Figure S5. GeoExplorer tends to explore more patches in the search areas, especially the inside patches. (a) *Statistics of the path end*. We count the end location of the 895 paths in the Masa dataset test set for ground truth (goal location), GOMAA-Geo and GeoExplorer when $C=4$ and $C=8$. (b) *Statistics of the path visited*. We count all the visited patches of 895 paths in the Masa dataset test set for GOMAA-Geo and GeoExplorer when $C=4$ and $C=8$.)

S5.2. 失效案例分析

我们对 GeoExplorer 的失败案例进行了检查和分析。图 S6 中所示的示例表明了失败的两个主要原因：(a) 目标信息不足；(b) 搜索区域同质化。在图 S6 (a) 中，目标位于水中，与周围的斑块非常相似，提供的定位信息有限。沿着生成的路径，已经访问了几个类似的斑块，但不是目标斑块。在图 S6 (b) 中，搜索区域内的所有斑块都很相似（例如，城市中的类似建筑斑块或山区的类似斑块），这可能会误导探索过程。




图 S6. 失败案例分析 (a) 目标信息不足，目标提供的定位信息有限。(b) 搜索区域同质化。搜索区域内的斑块相似，可能会误导探索。(Figure S6. Failure case analysis. (a) Insufficient target information. The target provides limited information for the localization. (b) Homogenized search area. Patches in the search area are similar and could mislead the exploration.)

S5.3. 其他路径可视化示例

为了进一步佐证我们的发现，我们提供了来自瑞士景观古迹数据集(图 S7)、马萨数据集(图 S8)和瑞士景观 100 数据集(图 S9)的更多可视化示例。这些图表展示了 GeoExplore 性能的关键方面，特别是在适应新环境和目标以及更优探索策略方面，并且证实了之前呈现的定量结果。具体而言，这三张图表明：

(1) GeoExplorer 在新环境中(图 S9，瑞士景观 100 示例)和面对不寻常及未见过的目标时(图 S7，瑞士景观古迹示例)取得了更高的成功率(SR) 并且泛化能力更强。(2) GeoExplorer 还能生成更多样化的路径，而基线模型(GOMAA-Geo)则倾向于沿着边缘区域进行探索，常常先朝向角落移动，然后再前往目标。这与主论文中的统计观察结果一致，该结果表明目标更常位于边缘和角落，这可能导致 GOMAA-Geo 在这些区域过度拟合。(3) 可视化样本也表明了

GeoExplorer 探索的稳健性。图 S8 的右图展示了目标位置的细微变化如何影响 Masa 数据集的探索过程。GeoExplorer 似乎更具稳健性，能够适应探索过程，并展现出多样且灵活的路径选择。相比之下，基线模型无论目标位置有怎样的小变化，都倾向于遵循相似的路径。图 S9 的右图展示了在 SwissView100 数据集上的另一种可控配置，其中上下两个示例中起点和目标的位置进行了互换，这表明 GeoExplorer 的探索对这种位置互换更具稳健性。此外，这两张图中的图像来自不同的平台，具有不同的分辨率，并且描绘的是不同的地点。这突显了所提出的数据集如何为该任务增强了数据多样性。

S5.4. 其他内在奖励可视化示例

为了进一步阐明内在奖励的特性，我们在图 S10 中提供了来自瑞士景观纪念碑数据集的更多样本。内在奖励较高的补丁通常是搜索区域内独特的补丁（例如，右列的第一个示例：城市区域中的绿地）或路径上的意外样本（例如，左栏的第一个示例：从城市区域移动到河流区域）。研究结果表明，内在奖励具有内容感知性，并通过密集且与目标无关的引导提高了模型的探索能力。



图 S7. 从瑞士古迹视图数据集生成的路径可视化，展示了航拍和地面视角下的目标
(Figure S7. Path visualization from the SwissViewMonuments dataset with goals presented in

aerial and ground views.)




图 S8. 从 Masa 数据集测试集中以鸟瞰图形式展示目标的路径可视化。在右侧，我们展示了具有更可控的 {起点, 目标} 配置的示例：目标补丁的位置略有变化，而起点补丁保持不变。(Figure S8. Path visualization from the Masa dataset test set with goals presented in aerial view. On the right, we show examples with more controllable {start, goal} configuration: the location of the goal patches changed slightly and the start patch remains the same.)




图 S9. 从 SwissView100 数据集生成的路径可视化，目标以鸟瞰图形式呈现。右侧展示了具有更多可控 {起点, 终点} 配置的示例：起点和终点位置互换。(Figure S9. Path visualization from the SwissView100 dataset with goals presented in aerial view. On the right, we show examples with more controllable {start, goal} configurations: with reversed start and goal locations)




图 S10. 使用来自 SwissViewMonuments 数据集的图像进行内在奖励可视化。对于每个样本，从左至右依次为：搜索区域、路径可视化以及每个补丁的内在奖励。在搜索区域中，具有最高内在奖励的补丁用橙色矩形突出显示。(Figure S10. Intrinsic reward visualization with images from the SwissViewMonuments dataset. For each sample, from left to right: the search area, path visualization and intrinsic reward per patch. The patch with the highest intrinsic reward is highlighted with an orange rectangle in the search area.)

S6. 讨论

作为一项新兴的研究课题，AGL 的任务配置仍存在一些局限性：（1）连续的状态和动作空间。目前，AGL 考虑的是状态和动作的网格状环境空间。例如，不同的状态之间没有重叠，动作是从离散空间中选择的。这种设置可以进一步改进为连续的状态和动作空间，以满足现实世界中搜索和救援任务的需求。（2）现实世界的开发。在无人机代理上开发模型时，还存在一些其他挑战，例如代理的自定位噪声和观测变形。这些挑战也应在 AGL 任务的进一步现实世界开发中予以考虑。

至于方法论，所提出的“好奇心驱动探索”在 AGL 任务中展现出了令人印象深刻的探索能力，并将鼓励未来的研究进一步理解智能体的探索模式。例如，深入研究和分析内在奖励如何影响外在奖励，以及全面分析如何将这两种动机结合起来，不仅会对 AGL 而且对其他目标导向的强化学习任务提供更深入的见解。

参考文献

- [1] Ebtesam Almazrouei, Hamza Alobeidli, Abdulaziz Alshamsi, Alessandro Cappelli, Ruxandra Cojocaru, Merouane Debbah, Etienne Goffinet, Daniel Hesslow, Julien Launay, Quentin Malartic, et al. The Falcon series of open language models (猎鹰系列开放语言模型). *arXiv preprint arXiv:2311.16867*, 2023. 6, 12
- [2] Guillaume Astruc, Nicolas Dufour, Ioannis Siglidis, Constantin Aronssohn, Nacim Bouia, Stephanie Fu, Romain Loiseau, Van Nguyen Nguyen, Charles Raude, Elliot Vincent, et al. OpenStreetView-5M: The many roads to global visual geolocation (OpenStreetView-5M: 通向全球视觉地理位置的多条道路). In *CVPR*, pages 21967–21977, 2024. 2, 14
- [3] Amir Bar, Gaoyue Zhou, Danny Tran, Trevor Darrell, and Yann LeCun. Navigation world models (导航世界模型). In *CVPR*, pages 15791–15801, 2025. 2, 4, 14
- [4] Gabriele Berton, Carlo Masone, and Barbara Caputo. Rethinking visual geo-localization for large-scale applications (重新思考大规模应用程序的可视地理定位). In *CVPR*, pages 4878–4888, 2022. 2, 14
- [5] Gabriele Berton, Riccardo Mereu, Gabriele Trivigno, Carlo Masone, Gabriela Csurka, Torsten Sattler, and Barbara Caputo. Deep visual geo-localization benchmark (深度视觉地理定位基准). In *CVPR*, pages 5396–5407, 2022. 2, 14
- [6] Yuri Burda, Harri Edwards, Deepak Pathak, Amos Storkey, Trevor Darrell, and Alexei A Efros. Large-scale study of curiosity-driven learning (对好奇心驱动型学习的大规模研究). In *ICLR*, 2018. 2, 3
- [7] David M. Chen, Georges Baatz, Kevin Koser, Sam S. Tsai, Ramakrishna Vedantham, Timo Pylväinen, Kimmo Roimela, Xin Chen, Jeff Bach, Marc Pollefeys, Bernd Girod, and Radek Grzeszczuk. City-scale landmark identification on mobile devices (移动设备上的城市级地标识别). In *CVPR*, pages 737–744, 2011. 14
- [8] Lili Chen, Kevin Lu, Aravind Rajeswaran, Kimin Lee, Aditya Grover, Misha Laskin, Pieter Abbeel, Aravind Srinivas, and Igor Mordatch. Decision transformer: Reinforcement learning via sequence modeling (决策转换器: 基于序列建模的强化学习). In *NeurIPS*, pages 15084–15097, 2021. 2, 4, 6, 7, 16
- [9] Aayush Dhakal, Adeel Ahmad, Subash Khanal, Srikumar Sastry, Hannah Kerner, and Nathan Jacobs. Sat2Cap: Mapping fine-grained textual descriptions from satellite images (Sat2Cap: 从卫星图像映射细粒度的文本描述). In *CVPRW*, pages 533–542, 2024. 3, 4, 6, 12
- [10] Dzung Doan, Yasir Latif, Tat-Jun Chin, Yu Liu, Thanh-Toan Do, and Ian Reid. Scalable place recognition under appearance change for autonomous driving (自动驾驶外观变化下的可伸缩位置识别). In *ICCV*, 2019. 14

- [11] Scott Emmons, Benjamin Eysenbach, Ilya Kostrikov, and Sergey Levine. RvS: What is essential for offline RL via supervised learning? (RVS: 通过监督学习实现离线 RL 的基本要素是什么?) In *ICLR*, 2022. 2
- [12] Yue Fan, Winson Chen, Tongzhou Jiang, Chun Zhou, Yi Zhang, and Xin Eric Wang. Aerial vision-and-dialog navigation (航空视觉和对话导航). In *ACL Findings 2023*, pages 3043–3061, 2022. 2, 14
- [13] Florian Fervers, Sebastian Bullinger, Christoph Bodensteiner, Michael Arens, and Rainer Stiefelhagen. Uncertainty-aware vision-based metric cross-view geolocalization (不确定性感知的基于视觉的度量交叉视点地理定位). In *CVPR*, pages 21621–21631, 2023. 14
- [14] Jing Gu, Eliana Stefani, Qi Wu, Jesse Thomason, and Xin Eric Wang. Vision-and-language navigation: A survey of tasks, methods, and future directions (视觉和语言导航: 对任务、方法和未来方向的概述). In *ACL*, pages 7606–7623, 2022. 14
- [15] Ritwik Gupta, Bryce Goodman, Nirav Patel, Ricky Hosfelt, Sandra Sajeew, Eric Heim, Jigar Doshi, Keane Lucas, Howie Choset, and Matthew Gaston. Creating xBD: A dataset for assessing building damage from satellite imagery (创建 XBD: 用于从卫星图像评估建筑物损坏的数据集). In *CVPRW*, pages 10–17, 2019. 5, 10
- [16] Danijar Hafner, Jurgis Pasukonis, Jimmy Ba, and Timothy Lillicrap. Mastering diverse domains through world models (通过世界模型掌握不同的领域). *arXiv preprint arXiv:2301.04104*, 2023. 4
- [17] Michael Janner, Qiyang Li, and Sergey Levine. Offline reinforcement learning as one big sequence modeling problem (离线强化学习作为一个大的序列建模问题). In *NeurIPS*, pages 1273–1286, 2021. 2
- [18] Mukul Khanna, Ram Ramrakhya, Gunjan Chhablani, Sriram Yenamandra, Theophile Gervet, Matthew Chang, Zsolt Kira, Devendra Singh Chaplot, Dhruv Batra, and Roozbeh Mottaghi. Goat-bench: A benchmark for multi-modal lifelong navigation (Goat-bench: 多模式长时间导航基准). In *CVPR*, pages 16373–16383, 2024. 14
- [19] Kuno Kim, Megumi Sano, Julian De Freitas, Nick Haber, and Daniel Yamins. Active world model learning with progress curiosity (好奇心进步驱动的主动世界模型). In *ICML*, pages 5306–5315, 2020. 2, 3
- [20] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning (可视化指令调谐). *NeurIPS*, 36:34892–34916, 2023. 10
- [21] Shubo Liu, Hongsheng Zhang, Yuankai Qi, Peng Wang, Yanning Zhang, and Qi Wu. AerialVLN: Vision-and-language navigation for uavs (AerialVLN: 无人机的视觉和语言导航). In *ICCV*, pages 15384–15394, 2023. 14
- [22] Zixian Ma, Rose Wang, Fei-Fei Li, Michael Bernstein, and Ranjay Krishna. ELIGN:

- Expectation alignment as a multiagent intrinsic reward (ELIGN: 期望一致作为一种多主体的内在奖励). In *NeurIPS*, pages 8304–8317, 2022. 3, 5
- [23] Ajith Anil Meera, Marija Popovic, Alexander Millane, and ‘ Roland Siegwart. Obstacle-aware adaptive informative path planning for uav-based target search (无人机目标搜索中的障碍物感知自适应信息路径规划). In *ICRA*, pages 718– 724, 2019. 1
- [24] Li Mi, Chang Xu, Javiera Castillo-Navarro, Syrielle Montariol, Wen Yang, Antoine Bosselut, and Devis Tuia. ConGeo: Robust cross-view geo-localization across ground view variations (ConGeo: 强大的跨地面视点变化的交叉视点地理定位). In *ECCV*, pages 214–230, 2024. 2
- [25] Volodymyr Mnih. *Machine learning for aerial image labeling* (用于航空图像标注的机器学习). PhD thesis, University of Toronto (Canada), 2013. 5, 10
- [26] Yasutaka Narazaki, Vedhus Hoskere, Girish Chowdhary, and Billie F Spencer Jr. Vision-based navigation planning for autonomous post-earthquake inspection of reinforced concrete railway viaducts using unmanned aerial vehicles (基于视觉的无人驾驶高架钢筋混凝土高架桥震后自主检测导航规划). *Automation in Construction*, 137:104214, 2022. 1
- [27] Aaron van den Oord, Yazhe Li, and Oriol Vinyals. Representation learning with contrastive predictive coding (采用对比预测编码的表征学习). *arXiv preprint arXiv:1807.03748*, 2018. 12
- [28] Deepak Pathak, Pulkit Agrawal, Alexei A Efros, and Trevor Darrell. Curiosity-driven exploration by self-supervised prediction (好奇心驱动的自我监督预测的探索). In *ICML*, pages 2778–2787, 2017. 2, 3, 4, 5
- [29] Aleksis Pirinen, Anton Samuelsson, John Backsund, and Kalle Astr º om. Aerial view localization with reinforcement º learning: Towards emulating search-and-rescue (基于强化学习的航拍定位: 向模拟搜救方向发展.). *Swedish Artificial Intelligence Society*, pages 28–37, 2023. 1, 2, 3, 5, 6, 7, 10, 13, 16
- [30] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. Improving language understanding by generative pre-training (通过生成性预训练提高语言理解能力). *OpenAI blog*, 2018. 6, 12
- [31] Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, Ilya Sutskever, et al. Language models are unsupervised multitask learners (语言模型是无人监督的多任务学习者). *OpenAI blog*, 2019. 2
- [32] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision (从自然语言监督中学习可移植的视觉模型). In *ICML*, pages 8748–8763, 2021. 3

- [33] Anindya Sarkar, Srikumar Sastry, Aleksis Pirinen, Chongjie Zhang, Nathan Jacobs, and Yevgeniy Vorobeychik. GOMAA-Geo: Goal modality agnostic active geolocalization (Gomaa-Geo: 目标模式不可知的主动地理定位). In *NeurIPS*, pages 104934–104964, 2024. 1, 2, 3, 4, 5, 6, 7, 10, 12, 13, 15, 16
- [34] Jurgen Schmidhuber. A possibility for implementing curiosity and boredom in model-building neural controllers (在建模神经控制器中实现好奇心和厌烦的可能性。正在进行中). In *Proc. of the International Conference on Simulation of Adaptive Behavior: From Animals to Animats*, pages 222–227, 1991. 3
- [35] Jurgen Schmidhuber. Reinforcement learning upside down: “Don’t predict rewards—just map them to actions” (强化学习颠倒：不要预测回报--只需将它们映射到行动). *arXiv preprint arXiv:1912.02875*, 2019. 2
- [36] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms (最近的策略优化算法). *arXiv preprint arXiv:1707.06347*, 2017. 4, 6, 7, 12, 16
- [37] Dhruv Shah, Ajay Sridhar, Nitish Dashora, Kyle Stachowicz, Kevin Black, Noriaki Hirose, and Sergey Levine. ViNT: A foundation model for visual navigation (可视化导航的基础模型). In *CoRL*, 2023. 14
- [38] Yujiao Shi, Fei Wu, Akhil Perincherry, Ankit Vora, and Hongdong Li. Boosting 3-dof ground-to-satellite camera localization accuracy via geometry-guided cross-view transformer (通过几何制导的横视变换提高三自由度地对星相机的定位精度). In *ICCV*, pages 21516–21526, 2023. 14
- [39] Tavis Shore, Oscar Mendez, and Simon Hadfield. PEnG: Pose-enhanced geo-localisation (PEnG: 姿势增强型地理定位). *IEEE Robotics and Automation Letters*, 10(4):3835–3842, 2025. 14
- [40] Rupesh Kumar Srivastava, Pranav Shyam, Filipe Mutz, Wojciech Jaskowski, and Jurgen Schmidhuber. Training agents using upside-down reinforcement learning (使用倒置强化学习来训练代理). *arXiv preprint arXiv:1912.02877*, 2019. 2
- [41] Bradly C Stadie, Sergey Levine, and Pieter Abbeel. Incentivizing exploration in reinforcement learning with deep predictive models (用深度预测模型激励强化学习中的探索). *arXiv preprint arXiv:1507.00814*, 2015. 2, 3
- [42] Vicente Vivanco Cepeda, Gaurav Kumar Nayak, and Mubarak Shah. GeoCLIP: Clip-inspired alignment between locations and images for effective worldwide geolocalization (GeoCLIP: 位置和图像之间以剪辑为灵感的对齐，以实现有效的全球地理定位). In *NeurIPS*, pages 8690–8701, 2023. 2, 14
- [43] Chen Wang, Linxi Fan, Jiankai Sun, Ruohan Zhang, Li FeiFei, Danfei Xu, Yuke Zhu, and

- Anima Anandkumar. MimicPlay: Long-horizon imitation learning by watching human play (MimicPlay: 通过观看人类游戏进行长期模仿学习) . In *CoRL*, 2023. 2
- [44] Xiaolong Wang, Runsen Xu, Zhuofan Cui, Zeyu Wan, and Yu Zhang. Fine-grained cross-view geo-localization using a correlation-aware homography estimator (使用相关性感知的单应性估计器的细粒度交叉视图地理定位) . In *NeurIPS*, pages 5301–5319, 2023. 2, 14
- [45] Xiangyu Wang, Donglin Yang, Ziqin Wang, Hohin Kwan, Jinyu Chen, Wenjun Wu, Hongsheng Li, Yue Liao, and Si Liu. Towards realistic uav vision-language navigation: Platform, benchmark, and methodology (走向逼真的无人机视觉语言导航: 平台、基准和方法。) . In *ICLR*, 2025. 14
- [46] A Waswani, N Shazeer, N Parmar, J Uszkoreit, L Jones, A Gomez, L Kaiser, and I Polosukhin. Attention is all you need (你所需要的就是关注) . In *NeurIPS*, 2017. 2
- [47] Scott Workman, Richard Souvenir, and Nathan Jacobs. Wide-area image geolocalization with aerial reference imagery (利用航空参考图像进行广域图像地理定位) . In *ICCV*, pages 3961–3969, 2015. 2, 14
- [48] Hongtao Wu, Ya Jing, Chilam Cheang, Guangzeng Chen, Jiafeng Xu, Xinghang Li, Minghuan Liu, Hang Li, and Tao Kong. Unleashing large-scale video generative pre-training for visual robot manipulation (开展视觉机器人操作的大规模视频生成性预训练) . In *ICLR*, 2024. 2
- [49] Zimin Xia and Alexandre Alahi. FG2: Fine-grained crossview localization by fine-grained feature matching (基于细粒度特征匹配的细粒度横视定位) . In *CVPR*, pages 6362–6372, 2025. 2, 14
- [50] Sherry Yang, Yilun Du, Seyed Kamyar Seyed Ghasemipour, Jonathan Tompson, Leslie Pack Kaelbling, Dale Schuurmans, and Pieter Abbeel. Learning interactive real-world simulators (学习交互式真实世界模拟器) . In *ICLR*, 2024. 2
- [51] Amir R Zamir, Asaad Hakeem, Luc Van Gool, Mubarak Shah, and Richard Szeliski. Introduction to large-scale visual geo-localization (大比例尺视觉地理定位导论) . In *Large-Scale Visual Geo-Localization*, pages 1–18. Springer, 2016. 2, 13, 14
- [52] Xiaohan Zhang, Xingyu Li, Waqas Sultani, Chen Chen, and Safwan Wshah. GeoDTR+: Toward generic cross-view geolocalization via geometric disentanglement (GeoDTR+: 通过几何解缠实现通用的跨视点地理定位) . *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46(12): 10419–10433, 2024. 14
- [53] Gaoyue Zhou, Hengkai Pan, Yann LeCun, and Lerrel Pinto. DINO-WM: World models on pre-trained visual features enable zero-shot planning (Dino-WM: 基于预先训练的视觉功能的世界模型支持零镜头规划) . In *ICML*, 2025. 2, 4
- [54] Sijie Zhu, Taojiannan Yang, and Chen Chen. VIGOR: Crossview image geo-localization

beyond one-to-one retrieval (VIGOR: 交叉搜索图像的地理定位超越了一对一检索).
In *CVPR*, pages 3640–3649, 2021. 2, 14