



東南大學

# 本科毕业设计（论文）报告

好奇心驱动的无人机主动定位目标导

航方法

|       |                         |
|-------|-------------------------|
| 学号:   | 08122215                |
| 姓名:   | 张洋                      |
| 学院:   | 自动化学院                   |
| 专业:   | 机器人工程                   |
| 指导教师: | 朱鹏飞、朱文成                 |
| 起止日期: | 2025. 12. 20-2026. 6. 3 |

2026 年 6 月 2 日

## 摘 要

无人机参与搜救、巡查和灾后评估时,经常面对目标位置不明、可见范围有限等情况,每次移动无人机只能观测当前位置附近的航拍图像块,选择错误方向还会影响后续决策。因而,这类任务不能简单看作目标识别问题,还需要无人机依据目标线索、局部观测和已有轨迹持续调整移动方向,在有限步数内接近目标区域。本文研究低空环境下的无人机主动目标定位导航任务,将搜索区域表示为航拍网格,并在主动地理定位框架中加入好奇心驱动的奖励设计。方法把航拍图像、地面图像和文本描述等目标线索纳入同一搜索过程,利用状态预测误差构造内在好奇心奖励,再结合距离门控和势函数奖励塑形,作为策略学习阶段的混合奖励信号。实验使用 MASA、MM-GAG、SwissView 和 xBD 等数据集,覆盖基础航拍搜索、多模态目标线索、跨区域测试和灾害前后搜索区域变化等条件。在 MM-GAG 上,航拍图像、地面图像和文本目标的平均成功率分别为 0.6170、0.6391 和 0.6247;  $10\times 10$  长距离扩展测试的平均成功率为 0.7480,平均最终距离为 0.7360。实验结果说明,该方法在不同目标线索和较长搜索路径下能够保持较稳定的目标接近能力。

关键词:无人机,好奇心驱动探索,主动目标定位,强化学习

# ABSTRACT

In search, inspection, and post-disaster assessment, UAV target locations are often unknown, and visual information is only partial. At each step, the UAV observes only the aerial patch around its current position. A wrong move may also change later observations and decisions. The problem is more than target recognition. It requires movement decisions based on target cues, local observations, and the accumulated trajectory within a finite number of steps. The task is formulated as active target localization and navigation for low-altitude UAVs. The search area is represented by an aerial grid. A curiosity-driven reward design is added to the active geo-localization framework. Aerial images, ground-view images, and text descriptions serve as target cues in the same search process. State prediction error provides the intrinsic curiosity reward, and distance gating together with potential-based reward shaping forms the mixed reward signal used for policy learning. The experiments use MASA, MM-GAG, SwissView, and xBD. These datasets cover basic aerial search, multimodal target cues, cross-region testing, and changes in search regions before and after disasters. On MM-GAG, the average success rates for aerial-image, ground-image, and text targets are 0.6170, 0.6391, and 0.6247. In the  $10\times 10$  long-distance test, the average success rate is 0.7480, and the average final distance is 0.7360. The method maintains stable target-approaching ability under different target cues and longer search paths.

KEY WORDS: UAV, Curiosity-Driven Exploration, Active Target Localization, Reinforcement Learning

# 目 录

|                                   |     |
|-----------------------------------|-----|
| 摘 要 .....                         | I   |
| ABSTRACT .....                    | II  |
| 目 录 .....                         | III |
| 第一章 绪论 .....                      | 1   |
| 1.1 研究背景和意义 .....                 | 1   |
| 1.2 国内外研究现状 .....                 | 1   |
| 1.2.1 国内研究现状 .....                | 1   |
| 1.2.2 国外研究现状 .....                | 3   |
| 1.3 本文研究内容 .....                  | 5   |
| 1.4 论文组织结构 .....                  | 5   |
| 第二章 背景知识与关键技术 .....               | 6   |
| 2.1 主动目标定位导航任务 .....              | 6   |
| 2.1.1 任务定义与设置 .....               | 6   |
| 2.1.2 主动目标定位导航研究 .....            | 6   |
| 2.2 强化学习与 PPO 策略优化方法 .....        | 9   |
| 2.3 好奇心驱动探索研究 .....               | 11  |
| 2.4 典型数据集介绍 .....                 | 14  |
| 2.5 本章小结 .....                    | 16  |
| 第三章 基于好奇心驱动的无人机主动目标定位导航方法设计 ..... | 17  |
| 3.1 方法总体框架 .....                  | 17  |
| 3.2 目标表示与状态构建 .....               | 18  |
| 3.3 动作-状态联合建模模块 .....             | 18  |
| 3.4 混合奖励机制设计 .....                | 19  |
| 3.5 基于 PPO 的策略学习与推理 .....         | 21  |
| 3.6 本章小结 .....                    | 22  |
| 第四章 实验结果与分析 .....                 | 23  |
| 4.1 实验设置 .....                    | 23  |
| 4.2 定量实验结果与分析 .....               | 24  |
| 4.3 定性可视化结果与分析 .....              | 27  |
| 4.4 消融实验 .....                    | 28  |

|                 |    |
|-----------------|----|
| 4.5 补充实验 .....  | 30 |
| 第五章 总结与展望 ..... | 33 |
| 5.1 工作总结 .....  | 33 |
| 5.2 不足与展望 ..... | 33 |
| 参考文献 .....      | 35 |
| 致 谢 .....       | 39 |

# 第一章 绪论

## 1.1 研究背景和意义

随着低空经济相关政策持续推进，城市治理、应急救援、交通巡检和灾害评估等场景对无人机的需求不断增加。人工智能、计算机视觉和具身智能的发展，也在推动无人机从图像采集平台转向具备环境感知、目标理解和自主决策能力的智能系统。由于部署灵活、视角开阔、到达速度快，低空无人机适合进入复杂地形、灾害现场以及人员难以快速抵达的区域。

在搜救、区域巡查和灾后评估任务中，目标位置常常无法预先确定，现场信息也要随着飞行过程逐步补充。不同于固定航线采集，无人机每次移动只能得到局部观测，错误动作还会占用有限搜索步数。此类搜索任务不能只依靠一次图像识别或静态匹配完成，还需要结合目标线索、当前观测和历史搜索过程，连续判断下一步移动方向<sup>[1]</sup>。

本文关注目标位置未知条件下的无人机主动目标定位导航。给定航拍搜索区域和目标线索后，无人机从起点出发，在每一步根据当前位置附近的图像块和历史搜索信息选择上、右、下、左中的一个移动动作，并在搜索预算内尽量到达目标网格。已有研究将这一过程建模为航拍图像网格上的主动定位任务<sup>[2]</sup>，并进一步扩展到航拍图像、地面图像和文本描述等多模态目标输入<sup>[3]</sup>。与一次性图像检索相比，该任务更强调搜索过程；与已知终点的路径规划相比，它又需要在目标位置未知时持续修正决策。

在上述任务中，主动目标定位导航可以看作无人机边移动、边感知、边判断下一步移动方向的过程。其难点主要来自三个方面：局部观测无法覆盖完整搜索区域，远距离阶段很难直接判断目标方向；相邻图像块外观相似时，策略容易在局部区域中反复移动；目标线索若来自地面图像或文本描述，还会与航拍观测产生视角和语义差异。外在奖励通常在接近目标时才更明确，搜索初期反馈不足。基于上述问题，本文研究好奇心驱动的无人机主动目标定位导航方法，利用状态预测误差为搜索过程补充探索信号，面向无人机搜救、区域巡查和灾后评估任务，尝试解决目标位置未知与局部观测受限下的搜索难题，使无人机在有限步数内更稳定地接近目标区域。

## 1.2 国内外研究现状

### 1.2.1 国内研究现状

近年来，国内无人机研究在自主飞行、低空视觉感知和任务级决策等方向已有较多积

累。以复杂环境中的自主飞行为例，浙江大学 FAST Lab 及相关团队长期关注未知场景下的轨迹规划与避障问题。Zhou 等人<sup>[4]</sup>提出的 EGO-Planner 不再依赖完整 ESDF（Euclidean Signed Distance Field）的显式构建，而是在局部轨迹优化中直接处理障碍约束。随后，RAPTOR<sup>[5]</sup>进一步把拓扑路径引导、风险感知和感知约束加入高速重规划，使无人机在快速飞行中能够主动观察潜在障碍区域。这类工作主要讨论安全飞行和实时运动规划，其中的动作约束和环境动态建模也与主动搜索任务有关。

在未知环境探索方面，FUEL<sup>[6]</sup>通过增量式前沿信息结构维护未知空间边界，并采用分层规划生成全局覆盖路径、局部视点和最小时间轨迹，提高了复杂空间中的无人机探索效率。RACER<sup>[7]</sup>进一步将探索对象扩展到多无人机协同场景，通过去中心化空间划分和任务分配实现快速协同探索。这些方法更关注空间覆盖、轨迹质量和安全约束，目标线索通常不以图像或文本等多模态形式参与决策。

低空视觉感知和数据集建设为无人机自主任务提供了评测基础。天津大学 AISKEYE 团队等构建的 VisDrone<sup>[8]</sup>基准覆盖城市和郊区低空场景，重点评测小目标、尺度变化和运动模糊条件下的检测、跟踪与计数算法。DroneCrowd<sup>[9]</sup>面向无人机密集人群视频，提供轨迹和头部标注，并给出检测、定位、计数和跟踪的联合基线。在视觉定位方面，UAV-VisLoc<sup>[10]</sup>构建了面向无人机视觉定位的大规模数据集，用于评估无人机视角与地理参考图像之间的匹配能力；JointLoc<sup>[11]</sup>将相对位姿和绝对位姿估计结合起来，用于行星无人机定位。这些工作为无人机在低空复杂场景中的感知、定位和数据驱动评测提供了支撑，也与视觉 SLAM 在无人机定位和场景感知中的发展趋势相一致<sup>[12]</sup>。

在前述感知和规划研究的基础上，国内团队也开始把语言指令、目标语义和任务级决策引入无人机导航，使无人机不只完成路径跟随，还需要理解任务目标。Liu 等人<sup>[13]</sup>提出 AerialVLN，将视觉语言导航扩展到无人机平台，研究无人机如何在城市级三维环境中结合自然语言指令和视觉观测完成路径决策。北京航空航天大学刘偲团队提出 OpenUAV<sup>[14]</sup>平台和 UAV-Need-Help 基准，在任务设置中加入无人机动力学、连续轨迹和多视角视觉输入，使视觉语言导航评测更接近实际飞行约束。周尧明团队的 AeroAgent<sup>[15]</sup>关注大型多模态模型在无人机任务中的高层决策作用，将多模态模型与 ROSchain 和无人机控制系统连接，用于搜索救援等具身任务。这些工作从不同侧面说明，无人机具身智能正在从单一模块研究转向视觉感知、语言理解、任务规划和飞行控制之间的闭环建模。

在无人机地理定位和多模态定位方面，国内团队近年来也提出了若干与本文任务更接

近的工作。Game4Loc<sup>[16]</sup>利用游戏环境构建大范围连续区域的 GTA-UAV 数据集，并将无人机图像与卫星图像的匹配从理想的一一对应扩展到更接近实际的部分匹配定位问题。MMGeo<sup>[17]</sup>进一步引入图像、点云、深度和文本等多模态信息，在卫星参考图中完成无人机组合式地理定位，提高了复杂环境下的定位鲁棒性。

总体来看，国内相关研究覆盖了无人机规划、未知环境探索、低空视觉数据集、视觉语言导航和多模态地理定位等方向。这些方向分别从飞行安全、环境覆盖、视觉感知、语义理解和跨视角匹配等角度推进无人机自主能力，也为本文讨论多模态目标条件下的主动搜索决策提供了任务背景。

### 1.2.2 国外研究现状

国外研究在视觉地理定位、具身导航和强化学习探索方面起步较早，形成了较清晰的任务演进路径。早期视觉地理定位多将定位问题表述为图像检索或跨视角匹配。Workman 等人<sup>[18]</sup>利用航拍参考图像进行大范围图像地理定位，说明航拍或卫星图像可以作为地面视觉定位的重要参考源。Vo 和 Hays<sup>[19]</sup>进一步研究了街景图像与俯视图之间的位置和朝向估计问题，将跨视角几何关系引入视觉定位过程。CVM-Net<sup>[20]</sup>采用孪生网络和 NetVLAD 聚合学习地面图像与航拍图像的共同嵌入空间，推动了深度跨视角地理定位方法的发展。OriCNN、SAFA<sup>[21,22]</sup>等方法进一步利用方向信息、极坐标变换和空间注意力缓解地面视角与航拍视角之间的几何差异。

随着任务设置逐步接近真实应用，跨视角地理定位研究开始从理想配对检索转向更复杂的定位条件。VIGOR<sup>[23]</sup>指出传统一一对应检索假设难以覆盖真实场景中查询图像任意出现的位置，因此构建了更接近实际的跨视角定位基准。TransGeo<sup>[24]</sup>将 Transformer 引入跨视角定位，通过全局关系建模和注意力裁剪提升了匹配效率与泛化能力。GeoCLIP<sup>[25]</sup>则借鉴 CLIP<sup>[39]</sup>的对齐思想，将图像特征与连续地理坐标编码进行对齐，扩展了世界范围图像地理定位的表达方式。这些研究主要围绕给定观测下的位置估计展开，为目标表示和跨视角匹配提供了方法基础。

主动地理定位则将地理定位过程进一步表述为序列决策问题。Pirinen 等人<sup>[2]</sup>提出 AiRLoc，将搜救场景中的目标搜索过程抽象为航拍图像网格上的主动定位任务，要求无人机在局部观测和有限步数下逐步接近目标区域。GOMAA-Geo<sup>[3]</sup>进一步将目标输入扩展为航拍图像、地面图像和文本描述等多种模态，并引入历史信息，使主动地理定位从单一目标图像检索转向目标模态无关的主动搜索。GeoExplorer<sup>[26]</sup>在主动地理定位中引入好奇心驱



动探索，通过内在奖励改善仅依赖外在距离奖励时的探索不足问题。这些工作为本文任务提供了直接参照，也说明主动定位需要同时处理目标表示、历史观测和动作选择之间的关系。

在相邻的具身导航方向，国外研究较早建立了视觉、语言和动作决策结合的评测体系。Anderson 等人<sup>[27]</sup>提出 Room-to-Room 视觉语言导航任务，要求智能体根据自然语言指令在真实室内环境中完成路径跟随。Mirowski 等人<sup>[28]</sup>构建 StreetLearn 环境，将导航范围扩展到城市街景尺度，重点考察无显式地图条件下的地标表示学习和长距离路径决策。在通用评测平台方面，Habitat<sup>[29]</sup>为具身智能（embodied AI）提供了可复现实验平台，使视觉导航、目标导航和交互式任务能够在统一模拟平台上评估；ALFRED<sup>[30]</sup>则将自然语言指令、视觉感知和动作执行放入日常任务场景中，进一步强化了语言 grounding 与序列决策之间的联系。这些任务与无人机航拍网格搜索在视角和动力学约束上不同，但都涉及目标条件、局部观测和多步动作选择。

强化学习探索机制为主动定位任务提供了另一条研究线索。PPO（Proximal Policy Optimization）<sup>[31]</sup>通过裁剪目标函数提高策略优化稳定性，已成为许多视觉导航和主动搜索任务中的常用基础算法。在稀疏奖励条件下，Pathak 等人<sup>[32]</sup>提出 ICM（Intrinsic Curiosity Module），以状态预测误差构造内在奖励，鼓励智能体访问尚未充分理解的状态。Burda 等人<sup>[33,34]</sup>对好奇心驱动学习进行了大规模实验分析，并在 Random Network Distillation 中使用固定随机网络的预测误差作为探索奖励，以缓解高维观测下的探索困难。Savinov<sup>[35]</sup>提出基于可达性的 episodic curiosity，通过判断当前观测相对于记忆中的状态是否新颖来抑制无效重复探索。Plan2Explore<sup>[36]</sup>则基于自监督世界模型预测未来状态不确定性，将探索目标从即时预测误差扩展到对未来信息增益的估计。此外，Lin 等人<sup>[37]</sup>将内在好奇心用于无人机室内探索，验证了该机制在未知环境覆盖任务中的应用价值。

综合来看，国外相关研究从跨视角图像匹配、主动地理定位、具身导航和强化学习探索等方向展开，形成了从目标表示到序列决策的研究脉络。而跨视角定位研究主要解决目标线索与视觉观测之间的表示对齐问题；主动地理定位把静态匹配扩展为航拍网格中的连续搜索；具身导航研究强调语言、视觉和动作序列之间的关系；内在奖励方法则用于缓解稀疏奖励下的探索不足。本文任务同时涉及这些问题，但重点并不是重新设计基础视觉编码器或通用导航平台，而是在于多模态目标条件下改进无人机主动搜索过程中的状态建模和奖励设计。

### 1.3 本文研究内容

围绕无人机主动目标定位导航任务中目标位置未知、局部观测受限和外在奖励反馈不足等问题，本文主要开展以下研究。

（1）构建无人机主动目标定位导航任务表示。结合主动地理定位任务特点，对搜索区域、状态输入、动作空间、目标形式和评价指标进行定义，明确本文任务的输入输出关系与基本约束。

（2）设计好奇心驱动的主动搜索方法。方法将多模态目标线索编码为统一目标向量，并与局部观测、历史动作和位置特征共同构成状态表示；随后利用动作-状态联合建模模块预测下一步观测特征，并以状态预测误差构造好奇心内在奖励。外在奖励、距离感知门控和势函数奖励塑形共同用于调节探索与目标收敛之间的关系。

（3）在多个数据集上进行实验验证。实验使用 MASA、MM-GAG、SwissView 和 xBD 等数据集，分别考察基础航拍搜索、多模态目标输入、跨区域泛化和灾害前后外观变化等条件下的搜索效果。实验分析包括整体结果、初始距离条件下的结果变化、典型轨迹可视化和奖励机制消融。

### 1.4 论文组织结构

全文共分为五章，各章内容安排如下。

第一章为绪论，主要介绍课题研究背景与意义，梳理国内外相关研究现状，说明本文研究内容，并给出论文组织结构。

第二章介绍本文涉及的背景知识与关键技术，围绕主动目标定位导航任务建模展开，说明目标表示、强化学习、好奇心驱动探索等本文使用的关键技术，介绍本文使用到的数据集。

第三章为基于好奇心驱动的无人机主动目标定位导航方法，介绍本文方法的总体框架、目标表示、动作-状态联合建模、混合奖励机制以及策略学习与推理的具体实现方法。

第四章为实验结果与分析，介绍实验设置、评价指标和对比方法，并从初始距离分组、轨迹可视化以及消融实验等多方面分析方法的探索导航能力。

第五章为总结与展望，总结本文主要工作和实验结论，分析本文方法的不足，并给出未来的研究方向。

## 第二章 背景知识与关键技术

### 2.1 主动目标定位导航任务

#### 2.1.1 任务定义与设置

主动目标定位导航任务面向目标位置未知条件下的无人机搜索过程。与预设航线飞行不同，该任务不直接给出完整路径。无人机需要依据目标线索、当前位置观测和已有搜索信息选择移动方向，并在有限搜索步数内接近或到达目标区域。

在主动地理定位研究中，该问题通常被建模为离散网格环境中的序列决策任务。设预定义搜索区域为  $R$ ，其网格集合表示为  $G = \{g_{ij} | 1 \leq i \leq H, 1 \leq j \leq W\}$ ，其中， $H$  和  $W$  分别表示网格行数和列数，每个网格单元对应一块局部航拍图像。第  $t$  个时间步无人机所在网格单元记为  $c_t = (i_t, j_t) \in G$ ，当前位置对应的局部观测图像块记为  $o_t$ 。目标所在网格单元记为  $c_g = (i_g, j_g)$ ，目标描述记为  $q$ 。目标描述可以由航拍目标图像、地面视角图像或自然语言文本给出。

无人机的动作空间由四个基本移动方向组成： $A = \{\text{up}, \text{right}, \text{down}, \text{left}\}$ 。在第  $t$  步，无人机选择动作  $a_t$ ，并从  $c_t$  移动到相邻网格单元  $c_{t+1}$ ，然后获得下一时刻的局部观测。经过连续决策形成的网格搜索轨迹可写为：

$$\tau_c = (c_0, a_0, c_1, a_1, \dots, a_{T-1}, c_T) \quad (1)$$

其中， $c_0$  表示起始状态， $T$  为搜索终止时刻。设最大搜索预算为  $B$ ，若存在  $t \leq B$  使  $c_t = c_g$ ，则本次搜索成功；若预算耗尽后仍未到达目标网格，则任务失败。目标接近程度通常可由当前网格与目标网格之间的曼哈顿距离衡量：

$$D(c_t, c_g) = |i_t - i_g| + |j_t - j_g| \quad (2)$$

这一任务包含三个基本约束：无人机每一步只能获得局部图像块，无法直接观察完整搜索区域；动作选择受目标线索约束，不能退化为无目标的区域覆盖；搜索预算有限，错误移动会减少后续修正机会。所以主动目标定位导航既不同于单次图像检索，也不同于已知终点条件下的路径规划。

#### 2.1.2 主动目标定位导航研究

主动地理定位建立在视觉地理定位研究基础上，但两类问题的侧重点并不相同。传统视觉地理定位通常给定查询图像，并在带有地理标签的图像库中检索或估计其位置<sup>[38]</sup>，重

点在于图像表示和跨视角匹配；主动地理定位则把定位过程放入连续搜索场景中，无人机需要在局部观测和搜索预算约束下逐步接近目标。也就是说，本文研究的方法关注的不只是当前观测与目标线索是否匹配，还包括策略如何利用连续观测和历史动作形成搜索决策。

AiRLoc<sup>[2]</sup>较早将无人机搜救中的目标搜索抽象为航拍图像网格上的主动定位任务。在该设置下，无人机从起始网格出发，根据当前位置的局部航拍图像、目标图像和历史搜索信息选择移动动作。AiRLoc 把目标定位从一次性图像匹配扩展为连续搜索过程，具体架构图如图 1 所示。





图 1 AiRLoc 框架图<sup>[2]</sup>

AiRLoc 的主要思想即状态与目标之间的匹配可概括为：

$$f(s_t, g) = \text{sim}(\phi(O_t), \psi(O^{\text{goal}})) \quad (3)$$

其中  $\phi(O_t)$  和  $\psi(O^{\text{goal}})$  分别表示当前观测和目标描述的特征编码， $\text{sim}(\cdot)$  表示相似度。公式(3)用于衡量当前状态与目标线索之间的匹配关系，并作为动作选择的参考。该框架展示了无人机在局部可观测条件下结合目标信息生成动作的基本流程。

GOMAA-Geo<sup>[3]</sup>在 AiRLoc 的基础上进一步扩展了目标形式，流程框架如图 2 所示。在实际无人机搜索中，目标线索不一定来自航拍图像，也可能来自地面图像或自然语言文本。GOMAA-Geo 将这一问题表述为多模态目标的主动地理定位任务：搜索过程中，目标描述则可以来自航拍图像、地面图像或文本。这样一来，任务难点不再只是如何在网格中移动到目标位置，还包括如何把不同形式的目标线索映射到可用于搜索决策的统一表示。

图 2 GOMAA-Geo 流程框架图<sup>[3]</sup>

无人机每一步接收当前位置的局部航拍图像和目标描述，并结合历史搜索信息形成状态表示，再由策略网络选择下一步动作。该过程可概括为选择使目标匹配得分较高的动作：

$$\hat{a}_t = \arg \max_{a \in A} f(s_t, g) \quad (4)$$

其中， $f(s_t, g)$  同样表示状态与目标之间的匹配程度。与 AiRLoc 相比，GOMAA-Geo 的目标可以由多种模态给出，状态表示也更强调连续观测和历史动作的利用。这种设计使模型能够在航拍图像、地面图像和文本目标之间复用搜索策略，也使主动地理定位更接近实际任务中目标线索来源复杂的情况。

与主动地理定位相邻的研究方向是无人机视觉语言导航。AerialVLN<sup>[13]</sup>将传统视觉语言导航从地面场景扩展到空中无人机平台，要求无人机根据自然语言指令和飞行过程中的视觉观测，在城市级三维环境中完成导航任务。该任务的输入包括自然语言指令和当前时刻的视觉观测，动作空间也包含前进、转向、上升、下降、平移和停止等动作。与主动地理定位相比，AerialVLN 更强调语言指令理解、地标关系推理和三维空间动作控制，其核心是指令跟随，并不直接等同于目标主动搜索。不过，两类任务都涉及视觉观测、目标或语言线索以及连续动作选择，因此 AerialVLN 可为多模态目标条件下的导航建模提供参考。

上述工作把地理定位从一次性图像匹配逐步推向带有动作约束的连续搜索。对于本文任务而言，难点不只在于判断当前图像块是否接近目标，还在于如何利用历史观测和动作信息持续修正搜索方向。这个特点也解释了为什么仅依靠即时匹配或距离奖励，在远距离目标和相似区域中容易出现不稳定搜索。

## 2.2 强化学习与 PPO 策略优化方法

主动目标定位导航具有典型的序列决策特征。无人机在每个时间步选择动作，动作会改变当前位置，也会影响下一步可获得的观测。强化学习适合描述这类交互过程，因为它不要求每一步都给出人工标注的正确动作，而是通过奖励信号引导策略学习。

本文任务中，搜索区域被划分为航拍网格；无人机携带目标线索，在网格间逐步移动，并接收当前位置附近的局部观测，上述交互过程可用马尔可夫决策过程（Markov Decision Process, MDP）描述。第 $t$ 步状态由当前位置观测、目标信息和已积累的搜索线索组成，动作对应无人机可选择的移动方向。动作执行后，环境返回新的观测和奖励，奖励反映本次移动是否更接近目标或命中目标。目标条件下的动作选择策略可写为：

$$a_t \sim \pi_\theta(a_t | s_t, g) \quad (5)$$

其中， $\pi_\theta$ 表示参数为 $\theta$ 的策略网络， $s_t$ 表示当前状态， $g$ 表示目标信息， $a_t$ 表示采样得到的动作。由于目标线索参与策略输入，同一位置在不同目标条件下可能对应不同的移动方向。

策略学习关注的不只是当前一步奖励，某次移动可能没有立即命中目标，但会使后续观测更接近目标区域。为了描述这种长期影响，从时刻 $t$ 开始的折扣累计回报可表示为：

$$G_t = \sum_{k=0}^{T-t} \gamma^k r_{t+k} \quad (6)$$

其中， $G_t$ 表示从时刻 $t$ 开始的累计回报， $\gamma \in [0,1]$ 为折扣因子， $r_{t+k}$ 表示后续第 $k$ 步获得的奖励。相比单步奖励，累计回报更能反映一段搜索策略对最终定位结果的影响。

为了衡量某个动作相对于平均水平是否更优，强化学习中常引入优势函数：

$$A_t = Q(s_t, a_t) - V(s_t) \quad (7)$$

其中， $Q(s_t, a_t)$ 表示在状态 $s_t$ 下执行动作 $a_t$ 后的期望回报， $V(s_t)$ 表示状态 $s_t$ 的价值。优势值为正时，该动作在相应状态下的选择概率提高；优势值为负时，选择概率降低。

无人机导航还具有明显的部分可观测性，单个航拍图像块只能反映局部区域，不能完全描述搜索空间。只依靠当前观测进行判断时，模型容易在外观相似的网格之间反复移动。因此，许多强化学习导航方法会把历史观测和历史动作加入状态表示，例如 GOMAA-Geo<sup>[3]</sup>在主动地理定位任务中也强调历史观测序列的作用，这与本文任务中的局部观测和连续搜

索过程是一致的。

在深度强化学习中，Actor-Critic 是一类常用的策略学习框架。Actor 负责根据当前状态输出动作分布，即学习策略  $\pi_\theta(a_t | s_t)$ ；Critic 负责估计状态价值或动作价值，用于评价 Actor 所选动作的好坏，两者共同完成策略更新。通常策略梯度方法的目标是沿着增加期望回报的方向更新策略参数，其基本梯度形式为：

$$\hat{g} = \mathbb{E}_t \left[ \nabla_\theta \log \pi_\theta(a_t | s_t) \hat{A}_t \right] \quad (8)$$

其中， $\hat{A}_t$  是优势函数的估计值， $\mathbb{E}_t$  表示对一批采样数据求经验平均。公式(8)中，优势估计值用于衡量采样动作相对当前策略的好坏，优势值较大的动作对梯度影响更强；优势值为负的动作，其选择概率会在相应状态下被压低。

实际训练中，同一批轨迹数据往往会被用于多轮小批量更新。如果新策略相对旧策略变化过大，采样轨迹和更新策略之间的差异会被放大，训练过程容易不稳定。PPO (Proximal Policy Optimization) 是基于策略梯度的常用强化学习算法，通过限制新旧策略的概率比变化来缓解这一问题。

PPO 将新旧策略概率比记为：

$$\varrho_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)} \quad (9)$$

其中， $\pi_{\theta_{\text{old}}}$  表示更新前的旧策略， $\pi_\theta$  表示当前待优化的新策略。当  $\varrho_t(\theta) > 1$  时，说明新策略提高了动作  $a_t$  的选择概率；当  $\varrho_t(\theta) < 1$  时，说明新策略降低了该动作的选择概率。

PPO 的裁剪目标函数表示为：

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[ \min \left( r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon) \hat{A}_t \right) \right] \quad (10)$$

其中， $\epsilon$  是裁剪超参数， $\text{clip}(\cdot)$  将概率比限制在  $[1-\epsilon, 1+\epsilon]$  范围内。裁剪机制使策略更新不会偏离旧策略太远。对于主动搜索任务，这一点比较重要，因为早期动作会影响后续观测；如果策略更新波动过大，搜索轨迹容易出现累积偏差。

实际实现时，PPO 的优化目标不只包含 Actor 侧的策略更新，还会加入 Critic 的价值估计误差和策略熵约束，可写为：

$$L_t(\theta) = \mathbb{E}_t \left[ L_t^{CLIP}(\theta) - c_1 L_t^{VF}(\theta) + c_2 S[\pi_\theta](s_t) \right] \quad (11)$$

其中， $L_t^{VF}(\theta)$  表示价值函数误差项， $S[\pi_\theta](s_t)$  表示策略熵， $c_1$  和  $c_2$  为权重系数。价值



函数损失用于约束 Critic 的估计，策略熵用于保留动作选择的多样性。对主动目标定位任务而言，PPO 并不改变搜索问题本身的建模方式，它主要用于稳定策略更新，使模型在稀疏反馈和多步搜索条件下能够较平稳地学习动作策略。

## 2.3 好奇心驱动探索研究

主动目标定位导航中的外在奖励大多来自目标接近程度、是否到达目标以及是否出现无效移动等条件。这类奖励目标明确，但反馈并不总是充分。无人机距离目标较远时，局部图像之间可能十分相似；目标线索若来自地面图像或文本描述，还会与航拍观测存在视角和语义差异。在这些情况下，仅依靠外在奖励容易使策略陷入局部移动，长时间得不到有效的搜索方向反馈。

针对稀疏反馈问题，已有研究常用内在奖励补充探索信号。内在奖励不直接来自任务成败，而是根据智能体与环境交互过程中获得的新信息构造。内在奖励的构造方式较多，常见方式包括基于状态访问频率、信息增益、模型不确定性和预测误差的奖励。基于访问频率的方法倾向于鼓励智能体进入较少访问的状态；基于信息增益或不确定性的方法强调智能体对环境认知的变化；基于预测误差的方法则利用模型对下一状态或动作后果的预测偏差，衡量当前状态转移中尚未被充分建模的部分。不同方法关注的角度有所差异，但共同目的都是在外在奖励不足时，为智能体提供额外的探索驱动。

外在奖励和内在奖励通常不会彼此孤立使用，而是以加权方式共同参与策略学习，可表示为：

$$r_t = r_{ex,t} + \alpha r_{in,t} \quad (12)$$

其中， $r_{ex,t}$  表示第  $t$  个时间步的外在奖励， $r_{in,t}$  表示内在奖励， $\alpha$  表示内在奖励权重。公式(12)反映了好奇心驱动方法的基本思路：外在奖励负责保持目标导向，内在奖励用于补充搜索初期和远距离阶段的探索动力，内外奖励的平衡会直接影响主动定位策略。

对视觉导航任务来说，预测误差型方法更容易与状态表示结合，因为每一步动作都会带来新的局部观测。预测误差型好奇心方法通常先根据当前状态和动作预测下一状态，这一过程可写为：

$$\hat{s}_{t+1} = f(s_t, a_t) \quad (13)$$

其中， $s_t$  表示当前状态， $a_t$  表示当前动作， $\hat{s}_{t+1}$  表示模型预测的下一状态。



再计算预测结果与真实下一状态之间的差异：

$$e_t = \|\hat{s}_{t+1} - s_{t+1}\|_2^2 \quad (14)$$

其中， $s_{t+1}$  为实际观测到的下一状态。预测误差较大时，说明当前状态转移对模型而言还没有被充分掌握；预测误差较小时，说明模型已经较熟悉该类转移。这样，状态预测误差就可以作为探索价值的度量。

Pathak 等人<sup>[32]</sup>提出的内在好奇心模块（Intrinsic Curiosity Module, ICM）是预测误差型好奇心的代表方法，架构图如图 3 所示。




图 3 ICM 框架图<sup>[32]</sup>

ICM 的好奇心奖励来自预测特征和真实特征之间的差异，可表示为：

$$r_t^i = \frac{\eta}{2} \|\hat{\phi}(s_{t+1}) - \phi(s_{t+1})\|_2^2 \quad (15)$$

其中， $\eta$  为缩放系数， $\phi(s_{t+1})$  表示真实下一状态的特征表示， $\hat{\phi}(s_{t+1})$  表示前向模型预测得到的下一状态特征。如果前向模型能够准确预测动作后的状态特征，说明当前转移对模型而言较熟悉，内在奖励较小；如果预测误差较大，说明该状态变化较难预测，智能体会获得更高的好奇心奖励。ICM 通过状态转移预测误差构造好奇心探索信号，并将该信号反馈给策略学习。

Burda 等人<sup>[33]</sup>在 ICM 等工作的基础上，对好奇心驱动学习进行了更大规模的实验研究。该工作重点不在于提出复杂的新模块，而是系统考察“只依靠内在奖励，智能体能否学到

有效探索行为”。其基本框架仍然围绕动态预测误差展开，即将观测  $x_t$  映射到特征表示  $\phi(x_t)$ ，再通过前向模型预测下一时刻特征，内在奖励可写为：

$$r_t = \|f(x_t, a_t) - \phi(x_{t+1})\|_2^2 \quad (16)$$

其中， $x_t$  表示当前观测， $a_t$  表示当前动作， $f(\cdot)$  表示前向预测模型， $\phi(\cdot)$  表示特征提取过程。该研究比较了原始像素、随机特征、逆动力学特征和 VAE 特征等不同特征空间对好奇心奖励的影响。实验结果表明，在一些视觉结构较简单的环境中，固定的随机特征也能形成有效探索信号；但在需要跨场景泛化的任务中，经过学习的特征表示往往更有优势。这一点对主动目标定位导航具有启发意义：内在奖励的效果不只取决于奖励公式本身，还取决于状态特征是否能够表达与搜索决策相关的信息。同时，该工作也指出预测误差型好奇心在随机性较强的环境中可能产生误导，因为不可预测并不一定等价于有价值的探索。

Plan2Explore<sup>[36]</sup>进一步将好奇心探索与世界模型结合起来。与只在智能体到达某个状态后再计算预测误差的做法不同，该方法先学习能够在潜在空间中预测未来状态的世界模型，再在模型内部生成未来轨迹，并选择预期信息增益较高的动作。




图 4 Plan2Explore 框架图<sup>[36]</sup>

其世界模型通常包含图像编码器、潜在状态转移模型、观测重构模型和奖励预测模型等部分，架构图如图 4 所示。可用如下形式表示潜在状态转移：

$$p(s_t | s_{t-1}, a_{t-1}) \quad (17)$$

为了估计未来状态的不确定性，Plan2Explore 使用多个一步预测模型组成的模型集，对同一潜在状态和动作给出不同预测，并用预测结果之间的分歧衡量模型不确定性。其潜在分歧奖励可简化表示为：

$$D(s_t, a_t) = \frac{1}{K-1} \sum_{k=1}^K \|\mu_k(s_t, a_t) - \bar{\mu}(s_t, a_t)\|^2 \quad (18)$$

其中， $K$  表示模型集中的预测模型数量， $\mu_k(s_t, a_t)$  表示第  $k$  个模型对下一潜在特征的预测均值， $\bar{\mu}(s_t, a_t)$  表示所有预测均值的平均值。分歧越大，说明模型对该动作后果的不确定性越高，因而该状态-动作组合具有更高探索价值。该方法的框架图可以概括为“观测编码-世界模型-潜在轨迹想象-模型分歧-探索策略更新”。相较于 ICM 对下一步动作后果的预测，Plan2Explore 更强调提前评估未来状态的不确定性，为导航任务中的状态预测和探索规划提供了参考。

对于无人机主动目标定位导航任务，状态预测具有较自然的适用性。无人机在网格化搜索区域中移动时，每个动作都会改变其所在位置，并影响下一时刻能够观测到的图像块。如果模型只根据当前观测直接预测动作，缺少对动作后果的理解，在长路径搜索或视觉内容相似的区域中容易出现判断偏差。而状态预测使模型关注“执行某个动作后可能进入什么状态”，从而帮助无人机理解动作与后续观测之间的关系。在这一意义上，动作信息和状态变化并不是彼此独立的，二者共同构成了主动搜索过程中的环境动态。GeoExplorer<sup>[26]</sup> 等主动地理定位研究也表明，当距离估计在未见目标或未见环境中变得不可靠时，引入与目标无关的好奇心奖励，有助于获得更稳健的探索行为。

好奇心驱动探索能够提高无人机对未知区域的访问意愿，但是内在奖励并非越强越好。如果内在奖励权重过大，无人机可能过度追求新奇区域，而偏离目标定位任务本身；如果内在奖励过弱，又难以缓解外在奖励稀疏带来的探索不足。因此，在主动目标定位导航研究中，好奇心机制的关键并不只是增加一个奖励项，而是要在目标收敛和主动探索之间保持合理平衡。

## 2.4 典型数据集介绍

主动地理定位的数据组织方式不同于普通图像分类或检索任务。相关论文通常将一幅航拍或遥感图像视为一个搜索区域，再将其划分为若干不重叠的图像块；一个任务样本由起点、目标位置、目标描述和搜索预算共同确定。这样，静态图像被转化为连续搜索环境，模型效果也可以按照起点到目标的初始距离进行分组评价。典型主动目标定位导航数据集场景示例如图 5 所示。




图 5 典型主动目标定位导航数据集场景示例

MASA<sup>[40]</sup>来源于 Massachusetts Buildings 航拍图像,是本文中基础航拍目标搜索的主要数据来源。在该数据集上,目标和当前位置观测都来自航拍视角,任务更接近同视角下的网格搜索,适合检验模型能否在航拍图像块之间学习基本的目标接近策略。MM-GAG<sup>[3]</sup>则把目标线索扩展到航拍图像、地面图像和文本描述三种形式。搜索过程仍发生在航拍图像网格中,但目标条件不再只来自同一视角,因此更适合观察模型在多模态目标输入下的搜索表现。

跨区域评测主要使用 SwissView 系列数据集<sup>[26]</sup>。SwissView100 覆盖瑞士地区的城市与自然场景,SwissViewMonuments 进一步选取地标建筑和自然景观等目标,并配有对应地面图像。这类数据与训练图像域存在差异,目标本身也更具体,因而适合检验模型面对未见区域和未见目标时的稳定性。xBD<sup>[41]</sup>数据集来自灾害评估场景,包含灾前和灾后遥感图像。在实验中,可以用灾前图像作为目标线索,再分别在灾前或灾后搜索区域中测试。建筑破坏、道路遮挡和地表纹理变化会改变局部外观,这一设置用于观察模型在跨时相图像变化下的搜索能力。

后续实验围绕这几类数据展开。MASA 用于基础航拍搜索,MM-GAG 用于多模态目标输入,SwissView 和 xBD 则分别补充跨区域、未见目标和灾害前后外观变化条件。这样

的设置使实验不只停留在单一同域数据上，也便于观察目标形式和场景变化对搜索结果的影响。

## 2.5 本章小结

本章从任务、方法和数据三个角度说明了后文需要使用的背景内容与技术。无人机主动目标定位导航可以看作目标条件下的连续搜索问题，当前位置观测、目标线索和历史搜索信息都会影响动作选择。**Actor-Critic** 策略网络给出了无人机探索动作策略学习的方法，而 **PPO** 算法用于稳定更新策略网络。好奇心驱动探索通过预测误差补充外在奖励不足时的训练信号。章末介绍的几个数据集分别对应基础航拍搜索、多模态目标输入和跨场景评测，后文的方法设计与实验设置均在这些设定下展开。



### 第三章 基于好奇心驱动的无人机主动目标定位导航方法设计

本章给出本文的无人机主动目标定位导航方法，方法围绕四个部分展开：目标表示、动作-状态联合建模、混合奖励机制和策略学习。目标表示用于处理航拍图像、地面图像和文本三类线索；动作-状态联合建模模块记录搜索过程，并预测下一步观测特征；混合奖励机制把外在奖励、好奇心内在奖励和势函数奖励塑形结合起来，用于训练搜索策略。

#### 3.1 方法总体框架

本文方法面向离散网格下的无人机主动目标定位导航任务。给定航拍搜索区域和目标线索后，无人机从起始网格出发，在每一步根据当前位置观测、目标表示和历史搜索序列选择移动动作，并在有限搜索预算内尽可能到达目标网格。搜索区域被划分为规则网格，每个网格对应一个局部航拍图像块，动作空间包括上、右、下、左四个方向。




图 6 本文方法总体框架示意图

图 6 给出了本文方法的总体框架。左侧为目标表示部分，目标线索可以来自航拍图像、地面图像或文本描述。航拍图像和地面图像经过视觉编码器得到目标特征，文本描述经过语义编码器得到目标特征。不同形式的目标输入由此被映射到统一特征空间，并作为后续状态建模和动作决策的目标条件。

中间部分为动作-特征序列建模过程。随着搜索推进，无人机在每一步执行动作并获得新的局部观测，历史动作与对应观测特征被组织为历史动作-特征序列。Transformer 根据该序列和目标特征建模当前搜索过程，输出当前状态特征，并预测动作执行后的下一步特征。预测特征与实际观测特征之间的误差用于构造好奇心内在奖励，当前状态特征则作为策略网络选择动作的输入。

右侧为策略决策和训练更新过程。Actor-Critic 策略网络根据当前状态特征输出动作分布，并在合法动作集合中选择下一步移动动作。动作执行后，新的观测及对应动作继续写入历史动作-特征序列，形成连续的闭环搜索过程。训练阶段，混合奖励机制综合外在目标奖励、好奇心内在奖励和势函数奖励塑形，用于计算 PPO 更新所需的回报和优势函数，并优化 Actor-Critic 网络参数。推理阶段不再进行参数更新，模型直接利用训练后的状态建模模块和 Actor 策略网络选择动作，直到到达目标网格或达到搜索预算上限。

### 3.2 目标表示与状态构建

目标线索可以由航拍图像、地面图像或文本描述给出。为使不同形式的目标能够进入同一决策流程，本文将三类目标分别编码为统一维度的目标向量。设航拍目标图像为  $I_a$ ，地面目标图像为  $I_g$ ，文本目标描述为  $T$ ，对应编码器分别记为  $E_a(\cdot)$ 、 $E_g(\cdot)$  和  $E_t(\cdot)$ ，三类目标特征可表示为：

$$z_a = E_a(I_a), \quad z_g = E_g(I_g), \quad z_t = E_t(T) \quad (19)$$

其中， $z_a$ 、 $z_g$  和  $z_t$  分别表示航拍图像、地面图像和文本描述的目标特征。在具体实现中，航拍图像块可通过面向遥感图像的 Sat2Cap/CLIP 视觉编码器提取特征，地面图像和文本描述则可分别通过 CLIP<sup>[39]</sup> 的视觉编码器和文本编码器获得特征表示。三类目标特征被映射到相同维度的特征空间，后续统一记为目标向量  $z$ 。

搜索区域中的每个网格图像块也被编码为视觉特征。设第  $t$  个时间步无人机所在位置的局部观测为  $o_t$ ，观测编码器为  $E_o(\cdot)$ ，则当前位置图像块特征为：

$$x_t = E_o(o_t) \quad (20)$$

为了保留连续搜索过程中的历史信息，本文将目标向量  $z$ 、历史观测特征  $\{x_0, \dots, x_t\}$ 、历史动作  $\{a_0, \dots, a_{t-1}\}$  和位置特征  $p_t$  共同组成动作-状态序列的输入。该输入同时包含目标条件、当前观测、访问顺序和空间位置关系，供后续策略学习和预测误差计算使用。

### 3.3 动作-状态联合建模模块

动作-状态联合建模模块接收目标线索、当前观测和历史搜索信息，将这些信息编码为策略决策所需的特征向量。除动作选择外，该特征向量还参与下一步观测特征预测。模型根据当前状态和候选动作估计下一时刻的观测特征，预测结果与真实观测特征之间的误差用于计算好奇心内在奖励。

设动作-状态序列为：

$$q_t = (z, x_0, a_0, x_1, a_1, \dots, x_t, p_t) \quad (21)$$

序列建模函数为  $F_\psi(\cdot)$ ，则当前状态向量可表示为：

$$h_t = F_\psi(q_t) \quad (22)$$

状态向量  $h_t$  一方面作为策略网络输入，另一方面用于下一状态预测。对于动作预测分支，模型根据  $h_t$  输出动作预测  $\hat{a}_t$ ，并与由目标方向确定的监督动作标签  $a_t^*$  计算动作预测损失：

$$L_{act} = CE(\hat{a}_t, a_t^*) \quad (23)$$

对于状态预测分支，模型通过预测函数  $P_\phi(\cdot)$  得到下一状态特征预测：

$$\hat{x}_{t+1} = P_\phi(h_t, a_t) \quad (24)$$

设真实下一状态特征为  $x_{t+1}$ ，状态预测误差为：

$$e_t = \|\hat{x}_{t+1} - x_{t+1}\|_2^2 \quad (25)$$

动作-状态建模阶段的总损失可写为：

$$L_{DM} = L_{act} + \alpha L_{state} \quad (26)$$

其中， $L_{state} = e_t$ ， $\alpha$  为状态预测损失权重。策略学习阶段主要使用该模块输出的状态向量  $h_t$  和预测误差  $e_t$ ，前者用于动作策略学习，后者用于构造内在奖励。

### 3.4 混合奖励机制设计

策略训练阶段的奖励由外在奖励、内在奖励和奖励塑形项组成。外在奖励反映任务目标本身，用于约束无人机向目标网格移动。本文将外在奖励分为三类：到达目标网格时给予较高正奖励；若动作后位置刷新历史最优接近程度，则给予正奖励；若动作导致原地停留、重复访问或未取得新的接近进展，则给予负奖励。

设当前网格单元为  $c_t$ ，执行动作后的下一网格单元为  $c_{t+1}$ ，目标网格单元为  $c_g$ ，已访问网格集合为  $\mathcal{V}_t$ ，距离函数为  $D(\cdot, \cdot)$ ，历史最优距离为  $D_{best}$ ，则外在奖励可写为：

$$r_{ex,t} = \begin{cases} 2, & c_{t+1} = c_g \\ 1, & c_{t+1} \neq c_t, c_{t+1} \notin \mathcal{V}_t, D(c_{t+1}, c_g) < D_{best} \\ -1, & c_{t+1} = c_t \text{ 或 } c_{t+1} \in \mathcal{V}_t \text{ 或 } D(c_{t+1}, c_g) \geq D_{best} \end{cases} \quad (27)$$



内在奖励由动作-状态联合建模模块的状态预测误差得到。设第  $t$  步的预测误差为：

$$e_t = \|\hat{s}_{t+1} - s_{t+1}\|_2^2 \quad (28)$$

则内在奖励写为：

$$r_{in,t} = \eta \cdot \text{Norm}(e_t) \quad (29)$$

其中， $\eta$  为缩放系数， $\text{Norm}(\cdot)$  表示对预测误差进行线性缩放、归一化或裁剪，使其与外在奖励处于相近量级。该项用于鼓励无人机访问尚未被模型充分预测的状态转移，为远距离搜索和陌生场景补充好奇心探索信号。

为控制内在奖励在不同搜索阶段的作用强度，本文采用距离感知门控。设当前时刻无人机到目标网格的距离为  $d_t = D(c_t, c_g)$ ，起点到目标的初始距离为  $C = D(c_0, c_g)$ 。由于实验任务中起点与目标不同， $C > 0$ 。归一化距离定义为：

$$\rho_t = \min\left(\frac{d_t}{C}, 1\right) \quad (30)$$

本文采用线性下界门控函数：

$$G(\rho_t) = g_{\min} + (1 - g_{\min})\rho_t \quad (31)$$

内在奖励权重进一步写为：

$$\lambda_t = \lambda_0 G(\rho_t) \quad (32)$$

其中， $\lambda_0$  为基础权重， $g_{\min}$  为门控下界。本文最终模型中  $g_{\min} = 0.405$ 。当无人机距离目标较远时， $\rho_t$  较大，内在奖励保持较高影响；当无人机接近目标时， $\rho_t$  减小，内在奖励权重降低但不会完全归零，从而减少接近目标后内在奖励对目标收敛的干扰。

此外，本文加入势函数奖励塑形项，对接近目标的过程提供连续反馈。设网格大小为  $K \times K$ ，最大曼哈顿距离为：

$$d_{\max} = 2(K - 1) \quad (33)$$

势函数定义为：

$$\Phi(c_t) = -\frac{D(c_t, c_g)}{d_{\max}} \quad (34)$$

当无人机由  $c_t$  移动到  $c_{t+1}$  时，塑形奖励为：

$$r_{\Phi,t} = \beta[\gamma\Phi(c_{t+1}) - \Phi(c_t)] \quad (35)$$

其中， $\beta$  为塑形项权重， $\gamma$  为折扣因子。

最终用于 PPO 更新的奖励为：

$$r_t = r_{ex,t} + \lambda_t r_{in,t} + r_{\Phi,t} \quad (36)$$

其中，外在奖励提供目标约束，内在奖励补充由状态转移预测误差形成的好奇心探索信号，距离感知门控调节内在奖励在不同搜索阶段的强度，势函数奖励塑形项提供连续趋近目标的塑形反馈。

### 3.5 基于 PPO 的策略学习与推理

获得状态表示和奖励信号后，本文采用 PPO 学习主动搜索策略。由于 2.2 强化学习与 PPO 策略优化方法已经介绍 PPO 的基本原理，本节仅说明其在本文方法中的使用方法。策略网络采用 Actor-Critic 结构，Actor 接收动作-状态联合建模模块输出的状态向量  $h_t$ ，并生成上、右、下、左四个动作的概率分布；Critic 根据同一状态向量估计状态价值，用于计算优势函数并辅助策略更新。

本文的 PPO 优化目标由策略损失、价值函数损失和熵正则项组成，可概括表示为：

$$L_{\text{train}} = L_{\text{policy}} + c_v L_{\text{value}} - c_H H(\pi_{\theta}(\cdot | h_t)) \quad (37)$$

其中， $L_{\text{policy}}$  表示 PPO 策略损失， $L_{\text{value}}$  表示价值函数损失， $H(\cdot)$  表示策略熵， $c_v$  为价值损失系数， $c_H$  为熵系数。本文在最终模型中降低熵系数  $c_H$ ，以减弱训练后期对随机动作的鼓励，使策略更倾向于沿已学习到的目标方向收敛。

动作选择还要考虑网格边界约束。无人机位于边界时，部分移动方向会越出搜索区域，因此需要在决策前将这些动作排除。一种常见做法是引入动作掩码：计算当前网格的合法动作集合，只在合法动作上重新归一化动作概率，从而避免策略输出无效方向。设网格单元  $c_t$  上合法动作集合为  $A_{\text{valid}}(c_t)$ ，则推理时动作选择可表示为：

$$a_t = \arg \max_{a \in A_{\text{valid}}(c_t)} \pi_{\theta}(a | h_t) \quad (38)$$

策略网络的熵项影响动作概率分布的集中程度。训练初期熵系数取值较高，动作分布均匀，智能体能够尝试不同移动方向。策略收敛之后，熵权重若仍然偏高，末端搜索步的动作抖动幅度增大，末端定位的稳定性下降。最终训练配置中将熵系数调低，使后期沿目标方向的移动稳定性更高。

推理阶段不再更新模型参数。系统根据当前的动作-状态序列生成状态向量，结合动作掩码剔除非法方向，然后选择概率最高的合法动作执行。无人机移动后更新局部观测和历史序列，继续搜索，直到命中目标网格或耗尽搜索预算。

### 3.6 本章小结

本章介绍了好奇心驱动的无人机主动目标定位导航方法。方法首先将航拍图像、地面图像和文本目标映射为统一目标向量，并结合局部观测、历史动作和位置特征构建状态表示。动作-状态联合建模模块用于编码搜索历史并预测下一步观测特征，预测误差进一步转化为好奇心内在奖励。混合奖励机制将外在奖励、距离门控内在奖励和势函数奖励塑形结合，用于平衡主动探索和目标收敛。最后，本文采用 PPO 训练 Actor-Critic 策略网络，并在推理阶段通过动作掩码保证动作合法性。

## 第四章 实验结果与分析

### 4.1 实验设置

实验采用离散网格搜索形式，每幅航拍图像被划分为 $5 \times 5$ 网格，每一步在上、右、下、左四个方向中选择一个合法动作。最大搜索预算设为 $B=10$ 。若无人机在预算内到达目标网格，则本次搜索记为成功；否则以终止位置到目标网格的距离评价其接近程度。为比较不同搜索难度下的表现，实验按照起点与目标之间的曼哈顿距离设置 $C=\{4,5,6,7,8\}$ 五类初始距离条件。测试阶段固定模型参数，每一步选择当前概率最高的合法动作，不进行在线更新。

实验数据按用途划分为训练集、验证集和测试集。训练集以 MASA 为主要数据来源，并引入 MM-GAG 补充多模态目标样本，二者样本比例为 3:1。MASA 提供航拍图像目标搜索环境，MM-GAG 同时包含航拍图像、地面图像和文本描述三类目标形式。测试阶段使用 MASA、MM-GAG、SwissView100、SwissViewMonuments 和 xBD 等数据源。SwissView 系列用于考察不同地理图像域和未见目标条件下的搜索表现；xBD 用于观察灾害前后图像外观变化对搜索的影响，其中 xBD-pre 表示灾前目标与灾前搜索区域的参考条件，xBD-disaster 表示灾前目标与灾后搜索区域的跨灾害迁移条件。

对比方法包括 Random policy、AiRLoc<sup>[2]</sup>、GOMAA-Geo<sup>[3]</sup>、GeoExplorer<sup>[26]</sup>和本文方法。Random policy 作为随机动作参照；GOMAA-Geo 与 GeoExplorer 为主动地理定位任务中的主要对比方法。本文方法为引入混合奖励机制的完整方法。

评价指标采用成功率 SR 和最终距离 SG。设测试样本数为  $N$ ，第  $i$  个样本的终止网格为  $c_T^{(i)}$ ，目标网格为  $c_g^{(i)}$ 。若无人机在搜索预算内到达目标网格，则记  $\mathbb{I}_i=1$ ，否则记为 0。

成功率 SR 表示预算内到达目标网格的样本比例，定义为：

$$SR = \frac{1}{N} \sum_{i=1}^N \mathbb{I}_i \quad (39)$$

最终距离 SG 采用搜索结束位置与目标网格之间的曼哈顿距离均值表示：

$$SG = \frac{1}{N} \sum_{i=1}^N D(c_i^{end}, c_i^g) \quad (40)$$

其中， $D(\cdot, \cdot)$  表示两个网格单元之间的曼哈顿距离。SR 越高，表示预算内命中目标的

比例越高；SG 越低，表示搜索结束时越接近目标网格。二者分别对应命中结果和终止位置，能够从不同侧面评价搜索策略。

## 4.2 定量实验结果与分析

MM-GAG 同时包含航拍图像目标、地面图像目标和文本目标，适合观察目标形式变化对搜索结果的影响。表 1 给出了 MM-GAG 上各方法的 SR 结果。A、G、T 分别表示航拍图像目标、地面图像目标和文本目标。Random policy 和 AiRLoc 只在航拍图像目标设置下列出，其余跨模态设置比较 GOMAA-Geo、GeoExplorer 和本文方法。其中  $C$  表示起点到终点的距离。

表 1 MM-GAG 不同目标模态下的 SR 对比

| 目标 | 方法          | $C = 4$       | $C = 5$       | $C = 6$       | $C = 7$       | $C = 8$       | 平均 SR $\uparrow$ |
|----|-------------|---------------|---------------|---------------|---------------|---------------|------------------|
| A  | Random      | 0.1447        | 0.0936        | 0.0553        | 0.0170        | 0.0298        | 0.0681           |
|    | AiRLoc      | <b>0.5660</b> | <b>0.4894</b> | 0.4894        | 0.4383        | 0.3191        | 0.4604           |
|    | GOMAA-Geo   | 0.3574        | 0.3872        | 0.5532        | 0.6298        | 0.7404        | 0.5336           |
|    | GeoExplorer | 0.3489        | 0.3745        | 0.5574        | 0.6851        | 0.6766        | 0.5285           |
|    | 本文方法        | 0.2681        | 0.3702        | <b>0.6809</b> | <b>0.8426</b> | <b>0.9234</b> | <b>0.6170</b>    |
| G  | GOMAA-Geo   | 0.3489        | 0.3745        | 0.5617        | 0.7064        | 0.7702        | 0.5523           |
|    | GeoExplorer | <b>0.4043</b> | 0.3745        | 0.5319        | 0.6681        | 0.7149        | 0.5387           |
|    | 本文方法        | 0.2766        | <b>0.4468</b> | <b>0.6511</b> | <b>0.9106</b> | <b>0.9106</b> | <b>0.6391</b>    |
| T  | GOMAA-Geo   | 0.3447        | 0.4213        | 0.5745        | 0.6596        | 0.7362        | 0.5472           |
|    | GeoExplorer | <b>0.3957</b> | 0.3660        | 0.4553        | 0.5660        | 0.6085        | 0.4783           |
|    | 本文方法        | 0.2681        | <b>0.4298</b> | <b>0.6596</b> | <b>0.8511</b> | <b>0.9149</b> | <b>0.6247</b>    |

本文方法在 A、G、T 三类目标上的平均 SR 分别为 0.6170、0.6391 和 0.6247，最大差值为 0.0221。文本目标的平均 SR 接近图像目标结果，地面图像目标的平均 SR 略高。三类输入没有出现明显失衡，目标线索经过统一编码后能够共同参与搜索决策。

AiRLoc 仅面向航拍图像目标，其平均 SR 为 0.4604。该方法在短距离条件下具有一定优势，但随着初始距离增大，成功率逐步下降。该趋势说明，长路径主动搜索对连续方向判断和历史信息利用提出了更高要求。

从初始距离条件看，本文方法的优势主要集中在中远距离任务。以文本目标为例， $C=6,7,8$  的 SR 分别为 0.6596、0.8511 和 0.9149；航拍图像目标在  $C=8$  上达到 0.9234，地面图像目标在  $C=8$  上为 0.9106。相比之下， $C=4$  组的 SR 偏低，近目标阶段仍容易受到局部相似图像块和末端动作选择的影响。整体来看，历史动作-特征建模和混合奖励机制更有利于多步搜索过程中保持目标导向。

表 2 进一步给出了 MM-GAG 上的 SG 结果。与 SR 相比，SG 更能反映失败样例中最终位置是否接近目标区域。本文方法在 A、G、T 三类目标上的平均 SG 分别为 1.1668、1.1055 和 1.1174，与 SR 中的三模态结果保持一致。三类目标的终止距离接近，说明不同目标形式没有造成明显的搜索偏移。

表 2 MM-GAG 不同目标模态下的 SG 对比

| 目标 | 方法          | $C=4$         | $C=5$         | $C=6$         | $C=7$         | $C=8$         | 平均 SG ↓       |
|----|-------------|---------------|---------------|---------------|---------------|---------------|---------------|
| A  | Random      | 3.1404        | 3.5617        | 3.8468        | 4.3362        | 4.9021        | 3.9574        |
|    | AiRLoc      | <b>1.0979</b> | <b>1.2979</b> | 1.3064        | 1.5362        | 2.0723        | 1.4621        |
|    | GOMAA-Geo   | 2.4340        | 1.9574        | 1.3106        | 0.9660        | 0.6553        | 1.4647        |
|    | GeoExplorer | 2.2213        | 1.9702        | 1.3277        | 0.9021        | 0.8681        | 1.4579        |
|    | 本文方法        | 2.5447        | 1.8553        | <b>0.8426</b> | <b>0.3532</b> | <b>0.2383</b> | <b>1.1668</b> |
| G  | GOMAA-Geo   | 2.3830        | 1.8340        | 1.2170        | 0.6596        | 0.6213        | 1.3430        |
|    | GeoExplorer | <b>2.0170</b> | 1.9106        | 1.3277        | 0.8596        | 0.8936        | 1.4017        |
|    | 本文方法        | 2.4766        | <b>1.7447</b> | <b>0.8681</b> | <b>0.2000</b> | <b>0.2383</b> | <b>1.1055</b> |
| T  | GOMAA-Geo   | 2.3064        | 1.8298        | 1.3021        | 0.7915        | 0.7404        | 1.3940        |
|    | GeoExplorer | <b>2.1191</b> | 2.0383        | 1.5915        | 1.2596        | 1.2851        | 1.6587        |
|    | 本文方法        | 2.5106        | <b>1.6085</b> | <b>0.9191</b> | <b>0.3447</b> | <b>0.2043</b> | <b>1.1174</b> |

SG 随初始距离变化的趋势与 SR 基本一致。文本目标在  $C=8$  条件下的 SG 为 0.2043，地面图像目标在  $C=7$  和  $C=8$  条件下的 SG 分别为 0.2000 和 0.2383，航拍图像目标在  $C=8$  条件下的 SG 为 0.2383。在较长路径条件下，终止位置整体更接近目标网格。

除 MM-GAG 外，本文还在 MASA、SwissView 和 xBD 上进行补充实验，如表 3 所示。表 3 列出 MASA 与 SwissView 系列结果。MASA 对应基础航拍搜索任务，SwissView 系列更强调跨区域和未见目标条件。

表 3 MASA 与 SwissView 数据集上的 SR / SG 对比

| 目标 | 数据集                | GOMAA-Geo       | GeoExplorer     | 本文方法                   |
|----|--------------------|-----------------|-----------------|------------------------|
| A  | MASA               | 0.5640 / 1.3600 | 0.5600 / 1.2560 | <b>0.5880 / 1.1440</b> |
|    | SwissView100       | 0.5044 / 1.5692 | 0.4700 / 1.5568 | <b>0.5772 / 1.3444</b> |
|    | SwissViewMonuments | 0.4314 / 1.6886 | 0.4337 / 1.7820 | <b>0.5059 / 1.5161</b> |
| G  | SwissViewMonuments | 0.4573 / 1.5851 | 0.4416 / 1.7647 | <b>0.4996 / 1.5388</b> |

在 MASA 上, 本文方法的 SR / SG 为 0.5880 / 1.1440。SwissView100 aerial 上的 SR 为 0.5772, SwissViewMonuments 的航拍目标和地面目标 SR 分别为 0.5059 和 0.4996。SwissViewMonuments 包含未见地标和新的图像域, 该结果反映出搜索策略并未完全依赖训练集中的同域纹理, 在跨区域条件下仍能保持一定命中率。

表 4 xBD 数据集上的 SR / SG 对比

| 目标 | 测评任务         | GOMAA-Geo       | GeoExplorer     | 本文方法                   |
|----|--------------|-----------------|-----------------|------------------------|
| A  | xBD-pre      | 0.5427 / 1.4132 | 0.5080 / 1.5555 | <b>0.5852 / 1.2922</b> |
|    | xBD-disaster | 0.5345 / 1.4194 | 0.5129 / 1.5452 | <b>0.5856 / 1.2839</b> |

xBD 评测中的目标图像均来自灾前航拍图像。表 4 中, xBD-pre 表示灾前目标与灾前搜索区域的参考条件, xBD-disaster 表示灾前目标与灾后搜索区域的跨灾害迁移条件。本文方法在 xBD-pre 与 xBD-disaster 上的 SR 分别为 0.5852 和 0.5856, SG 分别为 1.2922 和 1.2839。两组结果基本接近, 且灾后搜索区域上的 SR 没有下降, 说明模型在目标图像与搜索图像存在时相和外观差异时仍能保持稳定搜索, 体现了较强的跨图像泛化能力。

为考察导航定位方法在长路径的决策能力, 本文进一步进行  $10 \times 10$  网格长距离搜索扩展测试。测试仍采用 MASA 航拍图像目标任务, 搜索预算设为  $B = 32$ , 初始曼哈顿距离取  $C = \{14, 15, 16, 17, 18\}$ , 结果如表 5 所示。

表 5  $10 \times 10$  长距离搜索扩展测试结果

| 方法          | $C = 14$      | $C = 15$      | $C = 16$      | $C = 17$      | $C = 18$      | 平均 SR $\uparrow$ | 平均 SG $\downarrow$ |
|-------------|---------------|---------------|---------------|---------------|---------------|------------------|--------------------|
| GOMAA-Geo   | 0.5350        | 0.4750        | 0.6250        | 0.7500        | 0.7600        | 0.6290           | 1.8010             |
| GeoExplorer | 0.3350        | 0.3850        | 0.3350        | 0.2200        | 0.2250        | 0.3000           | 4.6770             |
| 本文方法        | <b>0.5400</b> | <b>0.6750</b> | <b>0.7550</b> | <b>0.8850</b> | <b>0.8850</b> | <b>0.7480</b>    | <b>0.7360</b>      |

在  $10 \times 10$  网格长距离测试中，本文方法的平均 SR 为 0.7480，平均 SG 为 0.7360。该设置下，起点与目标之间的距离明显增加，搜索过程更依赖连续多步的方向判断，本文方法在  $C=17$  和  $C=18$  条件下的 SR 均为 0.8850，终止距离也保持在较低水平。与 GOMAA-Geo 和 GeoExplorer 相比，本文方法在长路径条件下的误差累积更小，搜索终点更接近目标网格。

### 4.3 定性可视化结果与分析

轨迹可视化用于补充表格结果中难以体现的搜索过程，本文在 SwissViewMonuments 航拍图像任务中选取典型样例，展示不同初始距离条件下的成功轨迹。图 7 展示了本文方法在  $C=4$ 、 $C=6$  和  $C=8$  三个初始距离条件下的成功轨迹。图中绿色框表示起点，黄色框表示目标，数字标记表示无人机的移动顺序。在中远距离样例中，本文方法的轨迹没有频繁偏离目标方向，多数步骤沿着接近目标网格的方向推进。



图 7 本文方法在不同初始距离条件下的典型搜索轨迹

图 8 进一步比较了同一困难样例下本文方法、GOMAA-Geo 和 GeoExplorer 的搜索路径。该样例使用相同图像、起点和目标，初始距离为 6。本文方法的搜索轨迹为  $20 \rightarrow 21 \rightarrow 22 \rightarrow 17 \rightarrow 12 \rightarrow 7 \rightarrow 8 \rightarrow 3 \rightarrow 4 \rightarrow 9 \rightarrow 14$ ，最终到达目标网格 14；GOMAA-Geo 最终停留在网格 2，距离目标为 4；GeoExplorer 最终停留在网格 0，距离目标为 6。在视觉相似区域和较长路径条件下，本文方法表现出更稳定的目标接近趋势。






图 8 同一困难样例下三种方法的搜索轨迹对比

轨迹结果与前述 SR、SG 分析相互对应。本文方法的轨迹并非最短路径，但多步搜索中较少出现持续远离目标的动作序列。失败或困难样例中仍能观察到局部震荡，尤其在目标附近相邻网格外观相似时，末端几步容易出现反复选择。这也是短距离条件下结果波动较大的原因之一。

#### 4.4 消融实验

为分析奖励设计对搜索策略的影响，本文对混合奖励中的外在奖励、好奇心内在奖励、距离门控和势函数奖励塑形进行消融，混合奖励仍采用第三章中的公式(36)：

$$r_t = r_{ex,t} + \lambda_t r_{in,t} + r_{\Phi,t} \quad (41)$$

其中， $r_{ex,t}$  表示外在奖励， $r_{in,t}$  表示由状态预测误差得到的好奇心内在奖励， $r_{\Phi,t}$  表示势函数奖励塑形项， $\lambda_t$  为内在奖励门控权重。

为统一描述不同门控形式，设当前距离的归一化结果为：

$$\rho_t = \text{clip}\left(\frac{d_t}{d_*}, 0, 1\right) \quad (42)$$

其中， $d_t$  表示第  $t$  步无人机到目标网格的曼哈顿距离， $d_*$  表示当前任务起点到目标的最短路径步数。 $\rho_t$  越大，表示当前位置距离目标越远。带下界的门控权重可写为：

$$\lambda_t = \lambda_{\min} + (1 - \lambda_{\min})f(\rho_t) \quad (43)$$

其中， $\lambda_{\min}$  为门控下界，实验中取 0.405， $f(\rho_t)$  表示具体门控函数。本文比较了常数、线性、正弦和二次幂等形式；当  $\lambda_t = 1$  时，表示内在奖励不随距离变化。

不同门控函数可统一写为：

$$f(\rho_t) = \begin{cases} 0 & \text{Const} \\ \rho_t & \text{Line} \\ \sin\left(\frac{\pi}{2}\rho_t\right) & \text{Sin} \\ \rho_t^2 & \text{Power} \end{cases} \quad (44)$$

上述形式分别对应固定压低、线性调节、非线性平滑调节以及近目标阶段更强抑制的内在奖励调节方式。

表 6 以 MM-GAG 三类目标任务的成功率 SR 为指标，并按  $C = \{4, 5, 6, 7, 8\}$  的初始距离分组。常数 Const、线性 Line、正弦 Sin 和二次幂 Power 分别表示上述不同门控形式。

表 6 消融实验结果

| $r_{ex}$ | $r_{in}$ | $\lambda_t$ | $r_\Phi$ | $C = 4$       | $C = 5$       | $C = 6$       | $C = 7$       | $C = 8$       |
|----------|----------|-------------|----------|---------------|---------------|---------------|---------------|---------------|
| √        |          |             |          | 0.3617        | <b>0.4326</b> | 0.5801        | 0.7305        | 0.7773        |
| √        |          |             | √        | 0.3248        | 0.3546        | 0.6085        | 0.8014        | 0.8823        |
|          | √        | 1           |          | 0.1518        | 0.1064        | 0.0794        | 0.0752        | 0.0468        |
| √        | √        | 1           |          | 0.2525        | 0.3418        | 0.5816        | 0.8184        | 0.8369        |
| √        | √        | Const       |          | <b>0.3787</b> | 0.3972        | 0.5220        | 0.5929        | 0.5787        |
| √        | √        | Const       | √        | 0.3050        | 0.4099        | 0.5986        | 0.7816        | 0.8426        |
| √        | √        | Sin         |          | 0.3489        | 0.4241        | 0.4780        | 0.4028        | 0.2780        |
| √        | √        | Sin         | √        | 0.3177        | 0.3702        | 0.4879        | 0.4766        | 0.4596        |
| √        | √        | Power       |          | 0.2879        | 0.3475        | 0.4496        | 0.5986        | 0.6468        |
| √        | √        | Power       | √        | 0.2525        | 0.3291        | 0.5191        | 0.6809        | 0.7660        |
| √        | √        | Line        |          | 0.2695        | 0.3716        | 0.5787        | 0.8482        | 0.8426        |
| √        | √        | Line        | √        | 0.2709        | 0.4156        | <b>0.6638</b> | <b>0.8681</b> | <b>0.9163</b> |

仅使用好奇心内在奖励时，平均 SR 为 0.0919，远低于仅使用外在奖励的 0.5765。预测误差能够产生探索信号，但没有直接的目标约束，难以单独支撑定位。将好奇心内在奖励以  $\lambda_t = 1$  全程加入外在奖励后，平均 SR 为 0.5662，仍低于仅外在奖励。固定强度的内在奖励并不适合整个搜索过程；接近目标后，如果探索信号仍占据较大权重，策略容易继续搜索，而不是完成末端收敛。

势函数奖励塑形主要改善中远距离条件。仅使用外在奖励时， $C=8$  条件下的 SR 为 0.7773；加入势函数奖励塑形后提高到 0.8823，平均 SR 也从 0.5765 提高到 0.5943。该提升并不只出现在无内在奖励设置下。在常数门控、线性门控、正弦门控和二次幂门控中加入势函数奖励塑形后，平均 SR 分别由 0.4939、0.5821、0.3864 和 0.4661 提高到 0.5875、0.6270、0.4224 和 0.5095。可见势函数奖励塑形能够在不同内在奖励调节方式下提供额外的距离反馈，但其效果仍依赖门控函数形式。

不同门控形式之间结果差异较大。常数门控把内在奖励固定压低，平均 SR 为 0.4939；正弦和二次幂门控的平均 SR 分别为 0.3864 和 0.4661，加入势函数奖励塑形后仍低于线性门控组合。线性门控的变化更平缓：远距离阶段保留好奇心探索信号，接近目标后逐步减弱该信号，使末端定位更多依赖外在奖励和势函数奖励塑形。

#### 4.5 补充实验

前面几小节已给出在主要数据集上的对比结果、长距离测试结果和奖励机制消融结果。本节主要补充训练数据组合、关键参数取值和更大搜索范围下的实验结果，用于说明本文训练配置的选择依据和长路径搜索表现。实验内容包括训练数据集组合比较、参数取值分析、 $8\times 8$  与  $10\times 10$  网格长距离测试，以及  $25\times 25$  超大网格压力测试。

表 7 给出了不同训练数据组合下的 SR 与 SG 结果。MASA+MM-GAG 的数据组合在总体均值和迁移任务均值上均取得较好的结果，其中平均 SR 为 0.5765。从数据中可以看出 MASA+MM-GAG 在总体均值和迁移任务均值上表现更均衡，MASA 提供的航拍网格搜索样本和 MM-GAG 提供的多模态目标线索具有较好的互补性。直接合并更多数据反而并不一定带来进一步提升。

表 7 不同训练数据组合的成功率结果

| 测试集/<br>目标形式 | MASA   | MM-GAG | SwissView<br>100 | MM-GAG<br>+SwissView<br>w100 | MASA+<br>SwissView<br>100 | MASA+<br>MM-GAG | MASA+M<br>M-GAG+S<br>wissView1<br>00 |
|--------------|--------|--------|------------------|------------------------------|---------------------------|-----------------|--------------------------------------|
| MASA/A       | 0.4160 | 0.4640 | 0.3920           | 0.4400                       | 0.5840                    | <b>0.6200</b>   | 0.5440                               |
| MM-GAG/A     | 0.4332 | 0.4672 | 0.4255           | 0.5030                       | 0.5311                    | <b>0.6128</b>   | 0.4979                               |
| MM-GAG/G     | 0.4426 | 0.4494 | 0.4426           | 0.4911                       | 0.5268                    | <b>0.6102</b>   | 0.5038                               |
| MM-GAG/T     | 0.4162 | 0.4426 | 0.4204           | 0.4757                       | 0.5030                    | <b>0.6051</b>   | 0.4809                               |

续表 7 不同训练数据组合的成功率结果

| 测试集/目标形式                 | MASA   | MM-GAG | SwissView<br>100 | MM-GAG<br>+SwissView<br>w100 | MASA+<br>SwissView<br>100 | MASA+<br>MM-GAG | MASA+M<br>M-GAG+S<br>wissView1<br>00 |
|--------------------------|--------|--------|------------------|------------------------------|---------------------------|-----------------|--------------------------------------|
| SwissView100             | 0.3864 | 0.3872 | <b>0.7180</b>    | 0.7056                       | 0.6272                    | 0.5720          | 0.5756                               |
| SwissViewMo<br>numents/A | 0.4314 | 0.4220 | 0.3945           | 0.4510                       | 0.5043                    | <b>0.5059</b>   | 0.4565                               |
| SwissViewMo<br>numents/G | 0.4565 | 0.4243 | 0.4235           | 0.4682                       | <b>0.5012</b>             | 0.4996          | 0.4988                               |
| xBD/pre                  | 0.4113 | 0.4065 | 0.4705           | 0.5120                       | 0.5345                    | <b>0.5800</b>   | 0.4966                               |
| xBD/disaster             | 0.4140 | 0.4326 | 0.4475           | 0.5073                       | 0.5385                    | <b>0.5833</b>   | 0.4998                               |

表 8 汇总了熵系数  $c_H$ 、门控下界  $\lambda_{\min}$ 、势函数奖励塑形系数  $\beta$  主要取值分析实验结果。

表 8 参数取值分析实验结果

| 参数               | 取值设置         | 平均 SR $\uparrow$ | 平均 SG $\downarrow$ |
|------------------|--------------|------------------|--------------------|
| $c_H$            | 0.0025       | 0.5497           | 1.4166             |
|                  | <b>0.005</b> | <b>0.5765</b>    | <b>1.2885</b>      |
|                  | 0.0075       | 0.4344           | 2.0582             |
|                  | 0.0100       | 0.4729           | 1.7864             |
| $\lambda_{\min}$ | 0.100        | 0.4813           | 1.9150             |
|                  | 0.250        | 0.5009           | 1.7052             |
|                  | <b>0.405</b> | <b>0.5765</b>    | <b>1.2885</b>      |
|                  | 0.650        | 0.5089           | 1.6526             |
|                  | 0.900        | 0.4582           | 1.9135             |
| $\beta$          | 0.00         | 0.5535           | 1.3290             |
|                  | 0.05         | 0.5134           | 1.5409             |
|                  | <b>0.10</b>  | <b>0.5765</b>    | <b>1.2885</b>      |
|                  | 0.15         | 0.4933           | 1.7120             |
|                  | 0.20         | 0.5307           | 1.4880             |

正文采用的参数设置为熵系数为 0.005, 门控下界为 0.405, 势函数奖励塑形系数为 0.10。从实验数据来看, 正文采用的参数设置在多数指标上均较优。熵系数、门控下界的同组平均 SR 最高。

长距离测试用于观察搜索区域和初始距离扩大后的策略表现。表 9 给出了固定搜索预算下的总体结果。本文方法在三个网格设置下均取得更高 SR 和更低 SG, 且在远距离任务中有更大优势。

表 9 长距离测试结果

| 网格大小/<br>距离范围             | 搜索预算 | 方法          | 平均 SR ↑       | 平均 SG ↓        | $C_{\min}$ SR | $C_{\max}$ SR |
|---------------------------|------|-------------|---------------|----------------|---------------|---------------|
| 8×8<br>C=10,11,12,13,14   | 24   | GOMAA-Geo   | 0.6790        | 1.3450         | 0.4800        | 0.8200        |
|                           |      | GeoExplorer | 0.3680        | 3.0460         | 0.3850        | 0.3150        |
|                           |      | 本文方法        | <b>0.7460</b> | <b>0.8590</b>  | <b>0.5100</b> | <b>0.9250</b> |
| 10×10<br>C=14,15,16,17,18 | 32   | GOMAA-Geo   | 0.6290        | 1.8010         | 0.5350        | 0.7600        |
|                           |      | GeoExplorer | 0.3000        | 4.6770         | 0.3350        | 0.2250        |
|                           |      | 本文方法        | <b>0.7480</b> | <b>0.7360</b>  | <b>0.5400</b> | <b>0.8850</b> |
| 25×25<br>C=20,24,28,32,36 | 60   | GOMAA-Geo   | 0.1580        | 13.1920        | 0.0200        | 0.1400        |
|                           |      | GeoExplorer | 0.0840        | 14.3880        | <b>0.0400</b> | 0.0600        |
|                           |      | 本文方法        | <b>0.1820</b> | <b>12.3640</b> | 0.0200        | <b>0.2200</b> |

本节补充实验主要用于解释第四章主要结果背后的训练和测试条件。从训练数据看, MASA+MM-GAG 的组合在总体任务和迁移任务之间更均衡, 说明航拍搜索样本与多模态目标线索的配合比简单扩大数据来源更关键。参数取值分析显示, 熵系数、门控下界、势函数奖励塑形系数和验证距离都会影响策略结果, 正文采用的设置在多项指标之间保持了相对稳定和优势。长距离和超大网格测试则表明, 搜索范围扩大后任务难度明显上升, 但本文方法在终止距离和相对成功率上仍保持一定优势。上述结果补充说明了本文训练配置的合理性, 也从更大搜索尺度上验证了混合奖励方法对长路径搜索的支撑作用。

## 第五章 总结与展望

### 5.1 工作总结

本研究围绕低空无人机主动目标定位导航展开。任务中，目标位置并不预先给出，无人机只能依据当前位置航拍图像块、目标线索和已有搜索轨迹选择下一步移动方向。远距离阶段外在奖励反馈较弱，相邻网格外观相似时，单步图像匹配也容易产生方向偏差。针对这些问题，本文在主动地理定位框架中引入好奇心驱动的混合奖励设计，用状态预测误差为搜索过程补充训练信号。

本文方法把目标线索、搜索历史和奖励反馈放入同一决策流程。航拍图像、地面图像和文本目标先转换为统一维度的目标向量，局部观测、历史动作和位置特征随搜索过程进入动作-状态联合建模模块。该模块生成策略网络使用的状态特征，并预测动作执行后的下一步观测特征。预测误差作为好奇心内在奖励参与训练；外在奖励提供目标约束，距离门控调节内在奖励在不同距离阶段的强度，势函数奖励塑形补充连续距离反馈。这样的设计使远距离阶段仍有探索信号参与训练，接近目标后则减少探索项对收敛的干扰。

在 MM-GAG 数据集上，本文方法在航拍图像、地面图像和文本目标上的平均成功率分别为 0.6170、0.6391 和 0.6247，三类目标线索下没有出现明显失衡。长距离扩展测试中，本文方法取得 0.7480 的平均成功率，并在各距离条件下保持相对稳定的搜索结果。与现有方法相比，本文方法在中长路径搜索中更容易维持目标方向，说明历史搜索信息和混合奖励设计对多步决策具有一定作用。

消融实验显示，单独引入好奇心内在奖励时，策略更容易追逐预测误差较大的状态转移，目标约束反而被削弱；当内在奖励保持固定强度时，末端阶段的动作选择也会受到干扰。加入线性距离门控和势函数奖励塑形后，MM-GAG 三类目标平均成功率为 0.6270。从消融实验结果看，好奇心奖励更适合作为训练过程中的补充信号，需要与外在目标奖励和距离反馈配合使用。

### 5.2 不足与展望

现有实验以网格化航拍图像环境为主，搜索区域被切分为固定大小的图像块，动作也限定在上、右、下、左四个方向。这样设置便于分析初始距离、搜索预算和奖励设计之间的关系，但真实低空飞行还会受到连续位姿变化、速度约束和传感器误差影响。面向实际应用时，需要在仿真飞行平台中保留目标线索输入和奖励结构，并加入连续动作空间与动

力学约束，检验策略在飞行约束下的搜索表现。

目标表示也会影响策略决策。本文主要使用预提取的视觉和文本特征，目标条件进入策略前已经被压缩为特征向量。地面图像与航拍图像视角差异较大，或文本描述只提供较粗的语义信息时，目标线索与局部航拍观测之间的对应关系会变弱。未来可在目标编码阶段加入跨视角特征对齐和区域级语义表示，使目标信息能够更细地关联到搜索区域中的候选位置。

分距离结果显示，模型在  $C=6$  至  $C=8$  等中远距离条件下表现更稳定，短距离条件下反而出现波动。目标附近的多个图像块外观相近，错误移动一步即可能错过命中位置。因此，改进方向不是整体提高探索强度，而是针对末端阶段设计局部判别或终止判断机制，帮助模型在最后几步更准确地区分相邻网格。

可视化分析目前以典型样例为主，对搜索行为本身的统计尚不充分。轨迹中的回退次数、重复访问率、方向偏移幅度和近目标停留情况，均可用于分析奖励机制对策略的影响。若把这些行为指标与 SR、SG 结合起来，可以更细地观察模型是如何接近目标的。

## 参考文献

- [1] LIU H, LONG Q, YI B, et al. A survey of sensors based autonomous unmanned aerial vehicle (UAV) localization techniques[J]. *Complex & Intelligent Systems*, 2025, 11(8): 371.
- [2] PIRINEN A, SAMUELSSON A, BACKSUND J, et al. Aerial View Localization with Reinforcement Learning: Towards Emulating Search-and-Rescue[C]//*Proceedings of the 35th Annual Workshop of the Swedish Artificial Intelligence Society*. 2023: 28-37.
- [3] SARKAR A, SASTRY S, PIRINEN A, et al. GOMAA-Geo: GOal Modality Agnostic Active Geo-localization[C]//*Advances in Neural Information Processing Systems*. 2024: 104934-104964.
- [4] ZHOU X, WANG Z, YE H, et al. EGO-Planner: An ESDF-Free Gradient-Based Local Planner for Quadrotors[J]. *IEEE Robotics and Automation Letters*, 2021, 6(2): 478-485.
- [5] ZHOU B, PAN J, GAO F, et al. RAPTOR: Robust and Perception-Aware Trajectory Replanning for Quadrotor Fast Flight[J]. *IEEE Transactions on Robotics*, 2021, 37(6): 1992-2009.
- [6] ZHOU B, ZHANG Y, CHEN X, et al. FUEL: Fast UAV Exploration Using Incremental Frontier Structure and Hierarchical Planning[J]. *IEEE Robotics and Automation Letters*, 2021, 6(2): 779-786.
- [7] ZHOU B, XU H, SHEN S. RACER: Rapid Collaborative Exploration with a Decentralized Multi-UAV System[J]. *IEEE Transactions on Robotics*, 2023, 39(3): 1816-1835.
- [8] ZHU P, WEN L, DU D, et al. Detection and Tracking Meet Drones Challenge[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022, 44(11): 7380-7399.
- [9] WEN L, DU D, ZHU P, et al. Detection, Tracking, and Counting Meets Drones in Crowds: A Benchmark[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2021: 7812-7821.
- [10] XU W, YAO Y, CAO J, et al. UAV-VisLoc: A Large-scale Dataset for UAV Visual Localization[EB/OL]. *arXiv:2405.11936*, 2024.
- [11] LUO X, WAN X, GAO Y, et al. JointLoc: A Real-time Visual Localization Framework for Planetary UAVs Based on Joint Relative and Absolute Pose Estimation[EB/OL]. *arXiv:2405.07429*, 2024.
- [12] ZHUANG L, ZHONG X, XU L, et al. Visual SLAM for Unmanned Aerial Vehicles: Localization and Perception[J]. *Sensors*, 2024, 24(10): 2980.
- [13] LIU S, ZHANG H, QI Y, et al. AerialVLN: Vision-and-Language Navigation for UAVs[C]//*Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2023: 15384-15394.



- 
- [14] WANG X, YANG D, WANG Z, et al. Towards Realistic UAV Vision-Language Navigation: Platform, Benchmark, and Methodology[C]//International Conference on Learning Representations. 2025.
  - [15] ZHAO H, PAN F, PING H, et al. Agent as Cerebrum, Controller as Cerebellum: Implementing an Embodied LMM-based Agent on Drones[EB/OL]. arXiv:2311.15033, 2023.
  - [16] JI Y, HE B, TAN Z, et al. Game4Loc: A UAV Geo-Localization Benchmark from Game Data[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(4): 3913-3921.
  - [17] JI Y, HE B, TAN Z, et al. MMGeo: Multimodal Compositional Geo-Localization for UAVs[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 25165-25175.
  - [18] WORKMAN S, SOUVENIR R, JACOBS N. Wide-Area Image Geolocalization with Aerial Reference Imagery[C]//Proceedings of the IEEE International Conference on Computer Vision. 2015: 3961-3969.
  - [19] VO N N, HAYS J. Localizing and Orienting Street Views Using Overhead Imagery[C]//European Conference on Computer Vision. 2016: 494-509.
  - [20] HU S, FENG M, NGUYEN R M H, et al. CVM-Net: Cross-View Matching Network for Image-Based Ground-to-Aerial Geo-Localization[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7258-7267.
  - [21] LIU L, LI H. Lending Orientation to Neural Networks for Cross-View Geo-Localization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 5624-5633.
  - [22] SHI Y, LIU L, YU X, et al. Spatial-Aware Feature Aggregation for Image-Based Cross-View Geo-Localization[C]//Advances in Neural Information Processing Systems. 2019: 10090-10100.
  - [23] ZHU S, YANG T, CHEN C. VIGOR: Cross-View Image Geo-Localization Beyond One-to-One Retrieval[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 3640-3649.
  - [24] ZHU S, SHAH M, CHEN C. TransGeo: Transformer Is All You Need for Cross-View Image Geo-Localization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 1162-1171.
  - [25] CEPEDA V V, NAYAK G K, SHAH M. GeoCLIP: CLIP-Inspired Alignment between Locations and Images for Effective Worldwide Geo-localization[C]//Advances in Neural Information Processing Systems. 2023: 8690-8701.

- 
- [26] MI L, BECHAZ M, CHEN Z, et al. GeoExplorer: Active Geo-localization with Curiosity-Driven Exploration[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 6122-6131.
  - [27] ANDERSON P, WU Q, TENEY D, et al. Vision-and-Language Navigation: Interpreting Visually-Grounded Navigation Instructions in Real Environments[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 3674-3683.
  - [28] MIROWSKI P, GRIMES M K, MALINOWSKI M, et al. Learning to Navigate in Cities Without a Map[C]//Advances in Neural Information Processing Systems. 2018.
  - [29] SAVVA M, KADIAN A, MAKSYMETS O, et al. Habitat: A Platform for Embodied AI Research[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 9339-9347.
  - [30] SHRIDHAR M, THOMASON J, GORDON D, et al. ALFRED: A Benchmark for Interpreting Grounded Instructions for Everyday Tasks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 10740-10749.
  - [31] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal Policy Optimization Algorithms[EB/OL]. arXiv:1707.06347, 2017.
  - [32] PATHAK D, AGRAWAL P, EFROS A A, et al. Curiosity-driven Exploration by Self-supervised Prediction[C]//Proceedings of the 34th International Conference on Machine Learning. 2017: 2778-2787.
  - [33] BURDA Y, EDWARDS H, PATHAK D, et al. Large-Scale Study of Curiosity-Driven Learning[EB/OL]. arXiv:1808.04355, 2018.
  - [34] BURDA Y, EDWARDS H, STORKEY A, et al. Exploration by Random Network Distillation[C]//International Conference on Learning Representations. 2019.
  - [35] SAVINOV N, RAICHUK A, MARINIER R, et al. Episodic Curiosity through Reachability[C]//International Conference on Learning Representations. 2019.
  - [36] SEKAR R, RYBKIN O, DANIILIDIS K, et al. Planning to Explore via Self-Supervised World Models[C]//Proceedings of the 37th International Conference on Machine Learning. 2020: 8583-8592.
  - [37] LIN H Y, ZHANG X S, MUNIR S. UAV exploration for indoor navigation based on deep reinforcement learning and intrinsic curiosity[J]. Intelligent Systems with Applications, 2026, 29: 200618.
  - [38] BERTON G, MEREU R, TRIVIGNO G, et al. Deep Visual Geo-Localization

- Benchmark[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 5396-5407.
- [39] RADFORD A, KIM J W, HALLACY C, et al. Learning Transferable Visual Models From Natural Language Supervision[C]//Proceedings of the 38th International Conference on Machine Learning. 2021: 8748-8763.
- [40] MNIH V. Machine Learning for Aerial Image Labeling[D]. Toronto: University of Toronto, 2013.
- [41] GUPTA R, GOODMAN B, PATEL N, et al. Creating xBD: A Dataset for Assessing Building Damage from Satellite Imagery[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. 2019: 10-17.

## 致 谢

四年的本科学习即将结束，时光匆匆，步履不停，回望来路，满怀感恩。

首先要衷心感谢我的指导老师以及实验室孙一鸣老师。在研究思路、实验设计、论文结构和文字表达等方面，两位老师给予了我非常多具体而耐心的指导，帮助我一步步理清问题，也让我第一次真切体会到科研工作中的严谨与细致。

感谢我的家人，你们在学习和生活中一直给予我理解与支持。也感谢我的同学和朋友们，是你们的陪伴，让我的本科四年充满活力、温暖与难忘的瞬间。

最后，我想感谢这四年的经历，感谢自己，也感谢人生的这份幸运。高考成绩刚好踩在几所高校的录取线上，因为本人的语文成绩不太好，同时被两所学校刷下来，误打误撞进入了家人众所不周知的东南大学。很幸运来到南京，这座既有大都市活力又有深厚底蕴的城市，给了我太多惊喜。大学第一个宿舍桃 2A109，三个性格各异却都很善良的舍友，两年的 109 宿舍生活发生了无数经典传唱的故事，至今我们还在互相聊起。四年里，只有大一过了一个完整的暑假，剩下两个暑假都在学校打比赛。幸运的是，我遇到了两支很好的队友，尽管有一场比赛颗粒无收，整体收获非常丰厚——这些经历，足够我和高中同学分享很久。保研时求外校无门，却柳暗花明找到了现在这个非常好的实验室，依然是一份值得感恩的幸运。当然，也要谢谢自己的努力。没有这份努力，再多的幸运也抓不住。

独善吾身，止于至善。谨以这篇毕业论文，为这四年在人生写下一个逗号，然后转身，走向新的旅程。

止於至善



SOUTHEAST UNIVERSITY